

Clasificación Anticipada de Amenaza Meteorológica en Ecuador

Anthony Herrera

•

David Ramírez

•

Katherine Forero

El Problema



Objetivo: Anticipar el nivel de intensidad de precipitación del **mes siguiente** para una zona determinada.



Alcance: Exclusivamente meteorológico. No predecimos inundaciones ni riesgo de desastre (esto requeriría datos de vulnerabilidad, drenaje, etc.).



Restricción: Usar únicamente información meteorológica histórica y conocida hasta el mes actual.

$$X_{Z,t} \rightarrow Y_{Z,t+1}$$

X: Info. conocida hasta mes actual

$Y \in \{\text{Baja, Media, Alta}\}$ para el mes siguiente

Objetivo del Proyecto

Construir un clasificador multiclase

Desarrollar y evaluar un modelo capaz de aprender patrones climáticos históricos para:

- ✓ **Clasificar:** Categorizar la intensidad en Baja, Media o Alta.
- 🌐 **Generalizar Espacialmente:** Funcionar en zonas geográficas no vistas en el entrenamiento.
- 📅 **Generalizar Temporalmente:** Mantener precisión hacia años futuros.
- 📊 **Estimar:** Proveer probabilidades continuas para las tres clases.

Ejemplo de Inferencia



Metodología y Datos


 **Fuente de datos:** Reanálisis satelital ERA5-Land (1991–2025) transformado de horario a mensual para 15 zonas.

 **Variable Objetivo (Target):** Rx5day (Máximo acumulado en 5 días consecutivos).
Umbrales globales: Q33 = 37.35 mm | Q66 = 71.00 mm


 **Partición Temporal:**

- Desarrollo (Entrenamiento): ≤ 2017
- Validación: 2018 - 2021
- Test Temporal: 2022 - 2025

 **Holdout Espacial:** 3 zonas excluidas del entrenamiento (Santo Domingo, Macas, Nueva Loja).



Diseño: Ingeniería de Características



Se realizó un análisis riguroso de información mutua para evitar incluir decenas de rezagos redundantes o variables correlacionadas.

Total Features = 38 candidatas

11 actuales (mes t)

+ 11 lag 1 (memoria reciente, mes $t-1$)

+ 11 lag 11 (análogo estacional, mes $t-11$)

+ 2 geográficas (Lat, Lon)


+ 2 estacionales (Sen/Cos de mes)

+ 1 región (One-Hot categórica)

* Excluimos identificadores de zona o año para forzar al modelo a aprender meteorología, evitando fuga de datos o memorización geográfica.

Diseño: Comparación de Algoritmos y Tuning


Evaluamos 5 familias algorítmicas usando un estricto protocolo de **4 Folds Temporales Expansivos** integrados en un Pipeline (para evitar *data leakage* en preprocesamiento).



Modelo Evaluado	Búsqueda Principal	Mejor Configuración
Regresión Logística	C = 0.1, 1, 10	C = 0.1, k = all
Random Forest	depth, leaves	depth=18, k = all
XGBoost	depth, lr	depth=3, lr=0.08
SVM (RBF)	C = 1, 10, 30; γ	C = 1, γ = 0.05, k = all
MLP (Red Neuronal)	Capas ocultas, α	(64), α = 10^{-4} , k = 10

Resultados: Selección del Modelo

- Métrica Principal:** Se usó *Macro F1-Score* para dar igual peso a las 3 clases, mitigando el desbalance inherente.
- Ganador Absoluto:** SVM con Kernel RBF alcanzó el máximo rendimiento en Validación Cruzada (0.7188).
- Baseline Competitivo:** La "Climatología zona-mes" obtuvo 0.7123, evidenciando que la estacionalidad contiene mucha señal. SVM la supera sumando meteorología dinámica.




Resultados: Generalización y Desempeño

Etapas de Evaluación	Macro F1	Recall (Clase Alta)
CV Temporal (1992-2017)	0.7188	0.7131
Validación (2018-2021)	0.6895	0.7028
Test Temporal (2022-2025)	0.6880	0.7489
Holdout Espacial (Zonas nuevas)	0.6376	0.9300


Estabilidad Temporal: La caída entre Validación y Test fue mínima (0.0015), confirmando ausencia de *overfitting* severo.

Clase Media: Fue la más difícil de predecir por ser una zona de transición entre los extremos secos y húmedos.





Demo



Dificultades, Soluciones y Aprendizajes



Definición del Target

Medir anomalías locales (percentiles zona) distorsionaba la magnitud física. Lo resolvimos con **umbrales globales de Rx5day**.

Aprendizaje: Definir el target es más crítico que el algoritmo.



Fuga de Datos (Leakage)

El escalado y lags filtraban el futuro. Se resolvió integrando todo en un **Pipeline de scikit-learn** evaluado en Folds Cronológicos.

Aprendizaje: Métricas altas engañan sin diseño riguroso.



Obtención de Datos

INAMHI no ofrecía datos continuos ni listos para modelado. Se usó ERA5-Land y se transformó NetCDF a una tabla zona-mes.



Generalización Espacial

El rendimiento temporal fue estable (~0.69), pero en zonas no vistas bajó (~0.63). *Aprendizaje:* Extrapolar geografía es el mayor desafío; requiere mayor diversidad espacial en entrenamiento futuro.



Evaluación del Modelo

No bastaba mirar una métrica global. Se revisó Macro F1, matriz de confusión y recall de Amenaza Alta.



Selección de Variables

Más variables no mejoran automáticamente el desempeño. Se redujo el conjunto a 38 características con señales actuales, lag1, lag11, ubicación y estacionalidad.

espol Escuela Superior Politécnica del Litoral FACULTAD DE INGENIERÍA EN ELECTRICIDAD Y COMPUTACIÓN Inteligencia Artificial	David Enrique Ramirez Scamatoroz dramirez1@espol.edu.ec FIEC Katherine Sheila Forero Villota kforero@espol.edu.ec FIEC	Anthony Arturo Herrera León anthlleon@espol.edu.ec FIEC
--	--	--

PROBLEMA

En Ecuador, la lluvia varía mucho entre regiones como Costa, Sierra y Amazonía. Esto dificulta anticipar si el siguiente mes tendrá una amenaza **Baja, Media o Alta** por precipitación intensa. El reto fue construir una clasificación comparable entre zonas, sin depender solo de reglas locales o de una revisión manual de datos meteorológicos históricos.



- Diseñar y evaluar un modelo de aprendizaje automático supervisado para clasificar la amenaza mensual por precipitación en zonas seleccionadas del Ecuador, usando datos meteorológicos históricos y antecedentes del mes anterior al objetivo.



- Se construyó un pipeline con datos ERA5-Land. Los datos horarios fueron transformados en indicadores mensuales de precipitación, temperatura, humedad, viento y presión.
- La amenaza se definió con Rx5day, que mide la máxima precipitación acumulada en 5 días dentro de un mes. Con percentiles globales 33 y 66 se clasificó cada mes como **Baja**, **Media** o **Alta**.
- El modelo final fue un SVM con kernel RBF, entrenado con información observada del mes actual, antecedentes temporales y contexto geográfico/estacional.



- El modelo seleccionado fue **SVM con kernel RBF**, porque obtuvo el mejor equilibrio general en validación temporal.
- **Métricas principales:**
 - CV temporal 1991-2017: **Macro F1 = 71.88%**
 - Validación temporal 2018-2021: **Macro F1 = 68.95%**
 - Prueba temporal final 2022-2025: **Macro F1 = 68.80%**
 - Accuracy en prueba temporal final: **69.97%**
- El modelo mantuvo un rendimiento temporal estable al evaluar meses futuros en zonas conocidas.



- La definición del target fue clave para obtener una amenaza comparable entre zonas.
- La validación temporal permitió evaluar el modelo sin mezclar información futura.
- El SVM RBF logró un desempeño estable, con **Macro F1 = 68.80%** en prueba temporal final.
- La climatología y estacionalidad explican parte importante de la señal; el modelo aporta una mejora adicional sobre esos patrones.

- Construimos un dataset mensual a partir de datos meteorológicos horarios ERA5-Land.
- Definimos una metodología de amenaza usando Rx5day y percentiles globales.
- Comparamos modelos de clasificación supervisada y seleccionamos el SVM RBF como modelo final.
- Exportamos el modelo operativo y lo integramos con una interfaz local para consultar predicciones mensuales.