

Clasificación Anticipada de Amenaza Meteorológica en Ecuador

Anthony Herrera

•

David Ramírez

•

Katherine Forero

El Problema

- ☁️ **Objetivo:** Anticipar el nivel de intensidad de precipitación del **mes siguiente** para una zona determinada.
- 🎯 **Alcance:** Exclusivamente meteorológico. No predecimos inundaciones ni riesgo de desastre (esto requeriría datos de vulnerabilidad, drenaje, etc.).
- 🕒 **Restricción:** Usar únicamente información meteorológica histórica y conocida hasta el mes actual.

$$X_{Z,t} \rightarrow Y_{Z,t+1}$$

X: Info. conocida hasta mes actual

Y ∈ {Baja, Media, Alta} para el mes siguiente

Objetivo del Proyecto

Construir un clasificador multiclase

Desarrollar y evaluar un modelo capaz de aprender patrones climáticos históricos para:

- ✓ **Clasificar:** Categorizar la intensidad en Baja, Media o Alta.
- 🌐 **Generalizar Espacialmente:** Funcionar en zonas geográficas no vistas en el entrenamiento.
- 📅 **Generalizar Temporalmente:** Mantener precisión hacia años futuros.
- 📊 **Estimar:** Proveer probabilidades continuas para las tres clases.

Ejemplo de Inferencia



Metodología y Datos


 **Fuente de datos:** Reanálisis satelital ERA5-Land (1991–2025) transformado de horario a mensual para 15 zonas.

 **Variable Objetivo (Target):** Rx5day (Máximo acumulado en 5 días consecutivos).
Umbrales globales: Q33 = 37.35 mm | Q66 = 71.00 mm


 **Partición Temporal:**

- Desarrollo (Entrenamiento): ≤ 2017
- Validación: 2018 - 2021
- Test Temporal: 2022 - 2025

 **Holdout Espacial:** 3 zonas excluidas del entrenamiento (Santo Domingo, Macas, Nueva Loja).



Diseño: Ingeniería de Características



Se realizó un análisis riguroso de información mutua para evitar incluir decenas de rezagos redundantes o variables correlacionadas.

Total Features = 38 candidatas

11 actuales (mes t)

+ 11 lag 1 (memoria reciente, mes $t-1$)

+ 11 lag 11 (análogo estacional, mes $t-11$)

+ 2 geográficas (Lat, Lon)

+ 2 estacionales (Sen/Cos de mes)

+ 1 región (One-Hot categórica)

* Excluimos identificadores de zona o año para forzar al modelo a aprender meteorología, evitando fuga de datos o memorización geográfica.


Diseño: Comparación de Algoritmos y Tuning

Evaluamos 5 familias algorítmicas usando un estricto protocolo de **4 Folds Temporales Expansivos** integrados en un Pipeline (para evitar *data leakage* en preprocesamiento).

Modelo Evaluado	Búsqueda Principal	Mejor Configuración
Regresión Logística	C = 0.1, 1, 10	C = 0.1, k = all
Random Forest	depth, leaves	depth=18, k = all
XGBoost	depth, lr	depth=3, lr=0.08
SVM (RBF)	C = 1, 10, 30; γ	C = 1, γ = 0.05, k = all
MLP (Red Neuronal)	Capas ocultas, α	(64), α = 10^{-4} , k = 10

Resultados: Selección del Modelo

- Métrica Principal:** Se usó *Macro F1-Score* para dar igual peso a las 3 clases, mitigando el desbalance inherente.
- Ganador Absoluto:** SVM con Kernel RBF alcanzó el máximo rendimiento en Validación Cruzada (0.7188).
- Baseline Competitivo:** La "Climatología zona-mes" obtuvo 0.7123, evidenciando que la estacionalidad contiene mucha señal. SVM la supera sumando meteorología dinámica.




Resultados: Generalización y Desempeño

Etapas de Evaluación	Macro F1	Recall (Clase Alta)
CV Temporal (1992-2017)	0.7188	0.7131
Validación (2018-2021)	0.6895	0.7028
Test Temporal (2022-2025)	0.6880	0.7489
Holdout Espacial (Zonas nuevas)	0.6376	0.9300


Estabilidad Temporal: La caída entre Validación y Test fue mínima (0.0015), confirmando ausencia de *overfitting* severo.

Clase Media: Fue la más difícil de predecir por ser una zona de transición entre los extremos secos y húmedos.





Demo



Dificultades, Soluciones y Aprendizajes



Definición del Target

Medir anomalías locales (percentiles zona) distorsionaba la magnitud física. Lo resolvimos con **umbrales globales de Rx5day**.

Aprendizaje: Definir el target es más crítico que el algoritmo.



Fuga de Datos (Leakage)

El escalado y lags filtraban el futuro. Se resolvió integrando todo en un **Pipeline de scikit-learn** evaluado en Folds Cronológicos.

Aprendizaje: Métricas altas engañan sin diseño riguroso.



Obtención de Datos

INAMHI no ofrecía datos continuos ni listos para modelado. Se usó ERA5-Land y se transformó NetCDF a una tabla zona-mes.



Generalización Espacial

El rendimiento temporal fue estable (~0.69), pero en zonas no vistas bajó (~0.63). *Aprendizaje:* Extrapolar geografía es el mayor desafío; requiere mayor diversidad espacial en entrenamiento futuro.



Evaluación del Modelo

No bastaba mirar una métrica global. Se revisó Macro F1, matriz de confusión y recall de Amenaza Alta.



Selección de Variables

Más variables no mejoran automáticamente el desempeño. Se redujo el conjunto a 38 características con señales actuales, lag1, lag11, ubicación y estacionalidad.

Borrador de Póster Científico