

Escuela Superior Politécnica del Litoral
Facultad de Ingeniería en Electricidad y Computación

Materia: Inteligencia Artificial

Reporte final del proyecto de fin de curso

**Clasificación del nivel de amenaza
meteorológica por precipitación para el mes
siguiente en zonas seleccionadas del Ecuador
mediante aprendizaje automático a partir de
datos meteorológicos históricos**

Grupo #6

Katherine Forero
David Ramírez
Anthony Herrera

Profesor: Enrique Peláez J. Ph.D.

Índice

1. Descripción del Problema	2
1.1. Nombre del Proyecto	2
1.2. Formulación del Problema	2
1.3. Objetivo del Proyecto	2
1.4. Alcance y Limitaciones	2
2. Aspectos Específicos del Problema	3
2.1. Enfoque en la Amenaza Meteorológica vs. Riesgo Integral	3
2.2. Tratamiento de datos espaciotemporales (Aplanamiento de datos NetCDF a Tabular)	3
2.3. Variables de rezago temporal (Lag Features) y restricción del horizonte anticipado	4
3. Modelos finales de análisis y definición del problema	4
3.1. Datos y Parámetros Fundamentales del Problema	4
3.1.1. Conjunto de Datos de Entrada (Features)	5
3.1.2. Etiqueta de Salida (Target Y_{t+1})	5
3.2. Modelo del Espacio de Estados del Problema	5
3.3. Modelo de Actores, Casos de Uso y Flujo del Problema	6
3.3.1. Actores del Sistema	6
3.3.2. Diagrama y Descripción de Casos de Uso	6
4. Modelos finales de diseño de la solución (Implementación ML/IA)	8
4.1. Arquitectura General del Sistema y Pipeline de Aprendizaje Automático	8
4.2. Selección y Diseño del Modelo Optimo: SVM con Kernel RBF	11
4.3. Esquema de Evaluación del Diseño (Validación Temporal)	13
5. Descripción de la implementación	13
5.1. Entorno de Desarrollo y Hardware	13
5.2. Librerías de Software y Ecosistema de Datos	14
5.3. Decisiones Técnicas en el Modelado e Hiperparámetros	14
5.4. Serialización e Integración con la Interfaz de Usuario	17
6. Descripción de los Resultados	17
6.1. Estrategia de Evaluación y Justificación de Métricas	18
6.2. Resultados Globales de Validación Cruzada vs. Prueba Temporal	18
6.3. Análisis de Matriz de Confusión y Clasificación de Amenaza	19
6.4. Análisis de Importancia de Variables e Ingeniería Predictiva	20
7. Conclusiones e impactos	21
7.1. Conclusiones y Lecciones Aprendidas	21
7.2. Impactos Esperados y Posibilidades Futuras	22

1. Descripción del Problema

1.1. Nombre del Proyecto

Clasificación del nivel de amenaza meteorológica por precipitación para el mes siguiente en zonas seleccionadas del Ecuador mediante aprendizaje automático a partir de datos meteorológicos históricos.

1.2. Formulación del Problema

El Ecuador, por su ubicación geográfica y diversidad topográfica, presenta una alta variabilidad climática que incide directamente en los regímenes de precipitación. Históricamente, las lluvias intensas han provocado impactos significativos en la infraestructura, la agricultura y la seguridad de las poblaciones. Anticipar el comportamiento de las precipitaciones a mediano plazo (mensual) es un desafío computacional y meteorológico debido a la naturaleza dinámica del clima. En este contexto, el uso de técnicas de Inteligencia Artificial y Machine Learning permite analizar grandes volúmenes de datos históricos espaciotemporales e identificar patrones ocultos.

Ante esta realidad, el problema central radica en la necesidad de predecir el nivel de amenaza meteorológica por precipitación (Baja, Media, Alta) para el mes siguiente ($t + 1$) en 15 zonas meteorológicas seleccionadas del Ecuador. Para lograr esto de manera anticipada, los modelos predictivos están restringidos a utilizar únicamente la información histórica y actual disponible hasta el mes de consulta (t), sin incluir datos futuros de precipitación. La amenaza se definió mediante umbrales globales basados en percentiles históricos (específicamente el percentil 33 correspondiente a 37.3479 mm y el percentil 66 a 70.9957 mm de la variable Rx5day) calculados sobre las zonas de desarrollo, lo que sirve para clasificar en Baja, Media y Alta con una escala comparable.

1.3. Objetivo del Proyecto

Desarrollar un sistema de clasificación basado en Machine Learning tradicional que estime anticipadamente el nivel de amenaza meteorológica por precipitaciones intensas correspondiente al mes siguiente, utilizando el producto de reanálisis satelital ERA5-Land del catálogo Copernicus Climate Data Store. El sistema busca proveer una herramienta de clasificación mensual basada en datos históricos estructurados, comparando múltiples algoritmos (como Random Forest y SVM) frente a un modelo base (Regresión Logística).

1.4. Alcance y Limitaciones

- **Alcance de la predicción:** El sistema realiza una clasificación en tres categorías discretas (Baja, Media, Alta) de la amenaza meteorológica.
- **Naturaleza de la predicción:** El modelo **no** estima la cantidad exacta de lluvia diaria ni evalúa el riesgo integral de desastre (que implicaría sumar variables de

vulnerabilidad poblacional e infraestructura). Su alcance es netamente la *amenaza meteorológica*.

- **Técnicas utilizadas:** El modelo final seleccionado no fue de Deep Learning; se priorizó un clasificador clásico SVM RBF, aunque fue evaluado y comparado contra perceptrones multicapa (MLP) durante el proceso.
- **Restricción temporal:** La inferencia para el mes objetivo utiliza únicamente información disponible hasta el mes de consulta (t): variables meteorológicas del mes actual, antecedentes históricos tipo *lag* ($t - 1$ y $t - 11$), ubicación geográfica, región y codificación estacional del mes objetivo.

2. Aspectos Específicos del Problema

2.1. Enfoque en la Amenaza Meteorológica vs. Riesgo Integral

Uno de los principales aspectos resueltos durante la delimitación del proyecto fue la separación conceptual y técnica entre el riesgo de desastres la “amenaza meteorológica”. Un modelo de riesgo integral requeriría, además de datos climáticos, la integración de capas complejas de vulnerabilidad socioeconómica, densidad poblacional, topografía para modelado de inundaciones y calidad de la infraestructura local; datos que presentan altos niveles de ruido y son de difícil acceso a nivel nacional en Ecuador. Al acotar el problema estrictamente a la *amenaza meteorológica*, el proyecto se consolidó como un problema puro de clasificación de Machine Learning basado en datos históricos de precipitación y temperatura.

Este procedimiento permitió comparar todas las zonas bajo una misma escala física de precipitación extrema, evitando que cada zona tuviera una definición distinta de amenaza según su propia climatología local.

2.2. Tratamiento de datos espaciotemporales (Aplanamiento de datos NetCDF a Tabular)

El origen primario de la información del proyecto proviene del catálogo Copernicus Climate Data Store (producto de reanálisis ERA5-Land), cuyos datos se distribuyen en formato NetCDF4. Este formato almacena la información como un cubo multidimensional estructurado en al menos tres dimensiones: Tiempo, Latitud y Longitud. Las bibliotecas clásicas de Machine Learning en Python, como *scikit-learn*, requieren que los datos de entrada posean una estructura tabular estrictamente bidimensional (filas como instancias y columnas como características o *features*), lo que generó un problema de incompatibilidad arquitectónica de datos.

Para resolver este obstáculo, se implementó un proceso ETL (Extract, Transform, Load) que incluyó el “aplanamiento” (Flattening) del cubo de datos. Primeramente, se trabajó con 15 zonas meteorológicas seleccionadas del Ecuador, en lugar de una malla o

Bounding Box completo, para optimizar la carga computacional y centrarse en áreas de interés representativas. Posteriormente, las dimensiones temporales (diarias u horarias) se agregaron en registros mensuales. Finalmente, la matriz tridimensional se desempaquetó iterativamente para transformarla en un *DataFrame* de la librería Pandas. Como resultado de esta transformación, cada fila de la matriz de diseño final pasó a representar de manera unívoca un mes en una zona específica, con sus respectivas variables meteorológicas alineadas como columnas predictivas.

2.3. Variables de rezago temporal (Lag Features) y restricción del horizonte anticipado

El desafío técnico más significativo consistía en cumplir con la restricción de temporalidad: el sistema debía predecir el nivel de amenaza para el mes futuro ($t + 1$) utilizando únicamente los datos climáticos cerrados y conocidos hasta el mes actual (t). Dado que se optó por algoritmos de Machine Learning clásico (como Random Forest y Máquinas de Vectores de Soporte) en lugar de arquitecturas de Deep Learning secuencial (como Redes Neuronales Recurrentes o LSTMs), el modelo no poseía una "memoria temporal intrínseca para comprender el comportamiento cronológico del clima.

Este aspecto se solucionó mediante un fuerte trabajo de ingeniería de características (*Feature Engineering*), específicamente con la creación de variables de rezago temporal o *Lag Features*. Se instruyó al algoritmo de preprocesamiento para que desplazara las columnas de datos históricos (precipitación y temperatura) correspondientes a meses anteriores (e.g., $t - 1, t - 11$) y las alineara en la misma fila del mes objetivo a predecir. De esta manera, cuando el clasificador evalúa una instancia para emitir su predicción del mes siguiente, recibe de forma tabular el "contexto" del comportamiento atmosférico de los meses previos en esa coordenada exacta. Esto permitió transformar un problema complejo de series de tiempo puras en un problema supervisado multiclase robusto, dotando a los algoritmos tradicionales de la capacidad técnica para identificar tendencias estacionales y predecir de forma efectiva la amenaza futura sin incurrir en fuga de información (data leakage).

3. Modelos finales de análisis y definición del problema

3.1. Datos y Parámetros Fundamentales del Problema

Para la modelación formal del problema de clasificación de amenaza meteorológica, se identificaron y caracterizaron los datos de entrada, los hiperparámetros de ingeniería de datos y la variable de salida, estableciendo un marco matemático riguroso.

3.1.1. Conjunto de Datos de Entrada (Features)

La matriz de diseño X está constituida por observaciones mensuales geoespaciales estructuradas en las siguientes variables primarias y derivadas. Se excluyeron deliberadamente identificadores textuales (como ciudad.º "zona_id") y variables de año explícitas para evitar que los algoritmos memorizaran épocas o se sobreajustaran geográficamente, promoviendo la generalización a zonas no vistas.

- **Coordenadas Espaciales:** Latitud ($\text{lat} \in [-5, 0^\circ, 1, 5^\circ]$) y Longitud ($\text{lon} \in [-81, 0^\circ, -75, 0^\circ]$) que ubican de forma unívoca la celda en el Ecuador continental.
- **Identificador Temporal Cíclico:** El mes objetivo se codificó mediante transformaciones trigonométricas (target_month_sin , target_month_cos) para capturar la estacionalidad circular sin usar identificadores categóricos puros.
- **Variables Meteorológicas Actuales (Mes t):** Precipitación total acumulada (P_t), precipitaciones máximas en 5 días (rx5day), temperatura media (T_t), humedad relativa y presión superficial.
- **Variables de Rezago Temporal (Lags):** Se extrajo el contexto del .^antecedente inmediato del .^análogo estacional", generando los lags $t - 1$ (mes anterior) y $t - 11$ (mismo mes del año anterior al objetivo) para todas las variables numéricas.

3.1.2. Etiqueta de Salida (Target Y_{t+1})

La variable objetivo $Y_{t+1} \in \{\text{Baja}, \text{Media}, \text{Alta}\}$ codifica el nivel de amenaza meteorológica por precipitación para el mes subsiguiente ($t+1$). La asignación de la etiqueta Y_{t+1} para una zona (i) en el mes $t + 1$ se define matemáticamente mediante las reglas de decisión basadas en los percentiles históricos globales P_{33} y P_{66} de la variable base rx5day_mm calculados sobre las zonas de desarrollo (37.3479 mm y 70.9957 mm, respectivamente):

$$Y_{t+1}(i) = \begin{cases} \text{Baja}(0), & \text{si } P_{t+1}(i) \leq P_{33} \\ \text{Media}(1), & \text{si } P_{33} < P_{t+1}(i) \leq P_{66} \\ \text{Alta}(2), & \text{si } P_{t+1}(i) > P_{66} \end{cases} \quad (1)$$

3.2. Modelo del Espacio de Estados del Problema

Formalmente, el problema de estimación de amenaza meteorológica se modela como un espacio de estados simplificado (S, A, T, S_0, F) , donde el sistema avanza entre estados climáticos evaluados de forma mensual:

- **Conjunto de Estados (S):** Representa el vector de estado climatológico de una celda espacial en el tiempo t , definido por $s_t = (\text{lat}_i, \text{lon}_j, \text{mes_seno}, \text{mes_coseno}, X_t, X_{t-1}, X_{t-11})$. Cada estado $s_t \in \mathbb{R}^d$ encapsula la trayectoria meteorológica reciente.

- **Conjunto de Acciones/Transiciones (A):** Corresponde a la evolución temporal estocástica natural de la atmósfera al avanzar de un periodo mensual t al periodo $t + 1$, denotado como el operador de avance temporal $\Delta t = +1$ mes.
- **Función de Evaluación/Clasificación ($f : S \rightarrow Y$):** Es la función aprendida por el modelo de Machine Learning que mapea el vector de estado actual s_t a una categoría de amenaza futura $\hat{y}_{t+1} \in \{\text{Baja, Media, Alta}\}$.
- **Estado Inicial (S_0):** Registro inicial de variables climáticas de una coordenada específica en el mes t_0 con su respectivo historial de rezagos requeridos.
- **Estados Finales/Objetivo (F):** Emisión exitosa de la etiqueta de clasificación de amenaza posterior al cálculo de las probabilidades de pertenencia a cada clase multiclase $P(Y_{t+1} = c \mid s_t)$.

3.3. Modelo de Actores, Casos de Uso y Flujo del Problema

Para garantizar que la solución responda a las necesidades funcionales de los usuarios institucionales y responda a las correcciones establecidas en las entregas previas (Tarea 3 y Tarea 4), la definición de requerimientos se estructuró a partir de exactamente dos actores del dominio y dos casos de uso principales.

3.3.1. Actores del Sistema

- **Analista Técnico de Información Climática:** Usuario especializado encargado de realizar consultas detalladas por zona y periodo, evaluar los antecedentes históricos meteorológicos y revisar los vectores de probabilidad emitidos por el modelo para validar el contexto y nivel de confianza técnico de la clasificación.
- **Responsable de Planificación o Gestión de Riesgos:** Usuario institucional o tomador de decisiones que consulta la categoría de amenaza estimada (Baja, Media, Alta) para utilizar el resultado como insumo complementario durante la planificación preventiva y la asignación de recursos institucionales.

3.3.2. Diagrama y Descripción de Casos de Uso

El comportamiento del sistema frente a las necesidades de los usuarios se sintetiza en dos casos de uso consolidados:

Nombre	Visualizar resultados de la clasificación
ID	CU-01
Actores	Analista técnico de información climática; Responsable de planificación o gestión de riesgos
Descripción	Permite determinar el nivel de amenaza meteorológica (Baja, Media o Alta) asociado con la precipitación del mes siguiente para una zona geográfica y un periodo de referencia. Utiliza exclusivamente los antecedentes disponibles hasta el mes de consulta y, si la información histórica es insuficiente, no genera la clasificación.

Tabla 1: Caso de Uso CU-01: Visualizar resultados de la clasificación.

Nombre	Determinar el nivel de amenaza del mes siguiente
ID	CU-02
Actores	Analista técnico de información climática; Responsable de planificación o gestión de riesgos
Descripción	Permite visualizar la zona consultada, el mes de referencia, el mes objetivo, la categoría de amenaza estimada, las probabilidades asociadas a cada categoría (Baja, Media, Alta) y los antecedentes meteorológicos relacionados con la consulta.

Tabla 2: Caso de Uso CU-02: Determinar el nivel de amenaza del mes siguiente.




Figura 1: Diagrama UML de Casos de Uso del Sistema de Clasificación de Amenaza Meteorológica (2 Actores, 2 Casos de Uso).

El diagrama de la Figura 1 ilustra las interacciones descritas entre el Analista y los subsistemas de preprocesamiento, inferencia y visualización.

4. Modelos finales de diseño de la solución (Implementación ML/IA)

4.1. Arquitectura General del Sistema y Pipeline de Aprendizaje Automático

La solución se diseñó bajo una arquitectura en cascada orientada a pipelines de Machine Learning (ML). A diferencia del software tradicional, el diseño no se centra únicamente en la estructura de clases, sino en el flujo ininterrumpido de transformación de tensores de datos desde su estado crudo hasta la emisión de probabilidades predictivas.

El modelo de diseño final se articuló en las siguientes macro-fases integradas mediante la librería `scikit-learn`:

1. **Módulo de Ingesta y Codificación (Input Layer):** Recepción del DataFrame estructurado. Las variables de ubicación espaciales (Latitud y Longitud) se trataron como numéricas continuas para permitir extrapolación de zonas, mientras que la región geográfica (Costa, Sierra, Amazonía) se ingresó mediante codificación One-Hot (*OneHotEncoder*).
2. **Módulo de Filtrado por Información Mutua (*Feature Selection*):** Para evitar el problema de la "maldición de la dimensionalidad" (generado al incluir todos los lags $t - 1$ y $t - 11$ de cada variable), se diseñó un paso de selección de características. Se utilizó el método de **Información Mutua (*SelectKBest_MI*)**, el cual evalúa la dependencia no lineal entre cada característica tabular x_i y la clase objetivo Y , reteniendo estadísticamente únicamente el subconjunto de características (k) de mayor entropía predictiva.
3. **Módulo de Estandarización de Escala (*Standardization*):** Fundamental para modelos basados en distancias (como SVM o Regresión Logística) y regularización de Redes Neuronales. Se implementó un *StandardScaler* que sustrae la media y divide por la desviación estándar en cada característica continua, asegurando un espacio vectorial de media 0 y varianza 1.
4. **Módulo Estimador/Inferencia ML:** Etapa final del pipeline donde el tensor procesado se inyecta al estimador matemático óptimo seleccionado mediante validación cruzada. Para este proyecto, el diseño se acopló para recibir el núcleo ganador: **Support Vector Machine (SVM) con Kernel de Función de Base Radial (RBF)**.




Figura 2: Diagrama del flujo y pipeline general implementado.




Figura 3: Diagrama general de la arquitectura de la solución.

4.2. Selección y Diseño del Modelo Optimo: SVM con Kernel RBF

El diseño de la solución se fundamentó fuertemente en el análisis exploratorio de los hiperparámetros y su rendimiento en un esquema de Validación Cruzada (CV) Temporal (1991-2017). Se sometieron a prueba 5 familias de algoritmos: Modelos Lineales (Regresión Logística Multinomial), Árboles (Random Forest, XGBoost), Redes Neuronales Básicas (MLP) y Máquinas de Vectores de Soporte (SVM).




Figura 4: Familias de algoritmos de Machine Learning sometidos a evaluación en el proyecto.




Figura 5: Ejemplo de arquitectura evaluada basada en ensambles de árboles (Random Forest).

El diseño final del sistema adoptó el clasificador **SVM-RBF** debido a su superioridad técnica empírica en las métricas consolidadas del pipeline. El diseño matemático del SVM busca encontrar un hiperplano de separación óptimo en un espacio dimensional elevado, maximizando el "margen" de separación entre las clases Baja, Media y Alta.

La inclusión del **Kernel RBF (Radial Basis Function)** en el diseño fue decisiva. A diferencia de una Regresión Logística que traza límites lineales rectos, el Kernel RBF emplea el "truco del kernel" (Kernel Trick) para mapear implícitamente el vector de características climáticas hacia dimensiones infinitas. Esto permitió que el modelo capturara y aprendiera con alta precisión las fronteras de decisión complejas, difusas y altamente **no lineales** que caracterizan la interacción entre la lluvia, la temperatura y la altitud en el

territorio ecuatoriano.

Según el diseño optimizado extraído de los *GridSearchCV*, los hiperparámetros congelados para el pipeline en producción son:

- **Tolerancia a error (C):** $C = 1,0$, indicando un margen equilibrado que prioriza la generalización frente a años no vistos en el futuro.
- **Radio de influencia (γ):** $\gamma = 0,05$, determinando que cada registro meteorológico histórico tiene un radio de influencia específico para clasificar los meses vecinos en el espacio de características.
- **Selección de variables (k):** Se configuró en `.all`, permitiendo que el SVM con regularización interna ponderara las 38 características resultantes del preprocesamiento en lugar de truncarlas artificialmente.
- **Probabilidad:** Configurado en `True` (empleando el método de escalado de Platt) para que el diseño no devuelva únicamente una categoría seca (".^amenaza Alta"), sino un vector de distribución de probabilidad continua para la toma de decisiones ($P(\text{Alta}) = 0,85$, $P(\text{Media}) = 0,10$, $P(\text{Baja}) = 0,05$).

4.3. Esquema de Evaluación del Diseño (Validación Temporal)

Parte crítica del modelo de diseño fue la prevención de "fugas de información" temporales (*Look-ahead bias*). En el diseño de Machine Learning tradicional, usar la validación cruzada k -fold aleatoria (K-Fold normal) destruye la cronología, permitiendo que el modelo se entrene con datos, por ejemplo, del año 2012 para predecir el 2005.

Para resolver esto en el diseño, se implementó un esquema de **Folds Temporales Expandibles (Time Series Split)**. El modelo fue entrenado de manera iterativa "hacia el futuro". Por ejemplo:

- **Fold 1:** Entrena de 1992 a 2004 → Evalúa de 2005 a 2007.
- **Fold 4 (Final):** Entrena de 1992 a 2013 → Evalúa de 2014 a 2017.

Este diseño de validación asegura metodológicamente que el SVM evaluado reproduzca las condiciones reales de predicción, enfrentándose a un "futuro no visto" empleando estrictamente los patrones aprendidos del pasado.

5. Descripción de la implementación

5.1. Entorno de Desarrollo y Hardware

El desarrollo, preprocesamiento y entrenamiento del sistema se implementó íntegramente utilizando el lenguaje de programación **Python (versión 3.10+)**. Para gestionar la complejidad de los cálculos matriciales y el entrenamiento de los múltiples algoritmos

evaluados, se utilizó un entorno de *Jupyter Notebooks* ejecutado sobre la infraestructura de la nube, permitiendo una asignación dinámica de memoria RAM y aceleración de procesador (CPU) indispensable para iterar sobre las validaciones cruzadas.

5.2. Librerías de Software y Ecosistema de Datos

La implementación requirió la orquestación de diversas bibliotecas especializadas en ciencia de datos:

- **xarray y netCDF4:** Utilizadas en la primera etapa crítica del proyecto para abrir, indexar y manipular los cubos de datos geospaciales multidimensionales descargados del catálogo ERA5-Land de Copernicus.
- **pandas y numpy:** Fundamentales para transformar los datos procesados en estructuras tabulares clásicas (*DataFrames*), calcular indicadores mensuales, construir la matriz de modelado y generar variables de rezago temporal mediante desplazamientos de índices (**shift**). También se utilizaron para calcular los percentiles globales P_{33} y P_{66} de `rx5day_mm` sobre las zonas de desarrollo, que definen los umbrales de amenaza Baja, Media y Alta.
- **scikit-learn:** Constituyó el núcleo algorítmico del proyecto. Toda la lógica de transformación, escalado (**StandardScaler**), selección de características (**SelectKBest**), división temporal de los datos (**TimeSeriesSplit**) y la instanciación de los modelos (incluyendo **SVC** para Máquinas de Vectores de Soporte, **RandomForestClassifier** y **LogisticRegression**) provino de este framework.

5.3. Decisiones Técnicas en el Modelado e Hiperparámetros

La implementación definitiva requirió la toma de decisiones técnicas puntuales para garantizar la viabilidad del clasificador:

1. **Ingeniería de Características Geográficas y Cíclicas:** A nivel de código, se decidió no incluir el nombre de la 'provincia' o el 'año' para evitar un sobreajuste geográfico o histórico. En su lugar, el sistema implementó la latitud y longitud puras, combinadas con una codificación matemática (seno y coseno) para el número de mes, logrando que el modelo comprenda que diciembre (mes 12) está temporalmente adyacente a enero (mes 1).
2. **Búsqueda Extensiva de Hiperparámetros (*GridSearchCV*):** La configuración final del modelo no fue arbitraria, sino el producto de una búsqueda en cuadrícula exhaustiva evaluada con la métrica *Macro F1-Score*. Para el algoritmo ganador (SVM), se implementaron y probaron decenas de combinaciones. Los hiperparámetros definitivos implementados en el código de producción fueron: `kernel='rbf'`, parámetro de regularización `C=1.0`, coeficiente del kernel `gamma=0.05`, y `probability=True`.

3. **Pipeline Integrado:** Para evitar el riesgo de "filtración de datos" (data leakage) durante la implementación del escalado de variables, se codificó un objeto **Pipeline** de scikit-learn. Esto asegura que operaciones como el *StandardScaler* se apliquen estrictamente recalculando la media y varianza en cada subconjunto de entrenamiento de los *folds* temporales, sin contaminarse jamás con los datos de validación.




Figura 6: Diagrama de actividades detallando el flujo de procesamiento de los datos.

5.4. Serialización e Integración con la Interfaz de Usuario

Una decisión arquitectónica clave durante la implementación fue separar el backend de Machine Learning del frontend de visualización. Para ello, se implementó un backend local con **FastAPI**, encargado de cargar el modelo exportado en formato `.joblib`, recibir las consultas desde la interfaz y ejecutar la predicción en el computador del usuario. Esta arquitectura permite mantener el modelo desacoplado de la interfaz, facilita la ejecución local del prototipo y evita depender de servicios externos de inferencia.




Figura 7: Diagrama de secuencia del proceso de consulta desde la interfaz hasta la estimación.

- **Persistencia del Modelo:** El pipeline completo (con el escalador y el SVM-RBF ya ajustado) fue exportado a disco utilizando la librería `joblib` (`resultados/modelo_svm_rbf_operativo.joblib`). El modelo operativo se entrena con datos de desarrollo hasta el objetivo 2025-12, usando 4.896 filas y 12 zonas de desarrollo. No se reevalúa ni genera matriz nueva para el ambiente de producción; sus métricas provienen de las etapas de validación.
- **Backend Local (FastAPI):** Se desarrolló una API local con **FastAPI** que se encarga de servir las predicciones. Esta API carga el modelo `.joblib`, recibe las consultas de la interfaz, inyecta las observaciones históricas necesarias y ejecuta la estimación en el computador del usuario.
- **Frontend Interactivo:** La interfaz local consulta directamente al backend de FastAPI y muestra de manera interactiva la zona consultada, la categoría estimada y las probabilidades asociadas. Esta separación de responsabilidades permitió modernizar la arquitectura frente a un esquema estático basado en archivos JSON.

6. Descripción de los Resultados

La evaluación del sistema demostró empíricamente la efectividad de las técnicas de Machine Learning para modelar fenómenos atmosféricos no lineales. A continuación, se detallan las métricas y los hallazgos críticos obtenidos del pipeline definitivo (SVM-RBF).

6.1. Estrategia de Evaluación y Justificación de Métricas

Debido a que el problema se formuló como una clasificación multiclase con tres niveles de amenaza (Baja, Media y Alta), era necesario utilizar una métrica que evaluara el desempeño de forma equilibrada entre clases. Aunque la definición mediante percentiles globales permitió mantener una distribución relativamente balanceada en las zonas de desarrollo, el *Accuracy* por sí solo no era suficiente para analizar si el modelo funcionaba bien en las tres categorías.

Por esta razón, el sistema fue optimizado y medido principalmente mediante **Macro F1-Score**, una métrica que calcula el F1 de cada clase y luego promedia los resultados dando el mismo peso a Baja, Media y Alta. Además, se revisó el **Recall de la clase Amenaza Alta**, ya que en un contexto de prevención resulta importante identificar correctamente los meses con mayor intensidad de precipitación.

6.2. Resultados Globales de Validación Cruzada vs. Prueba Temporal

Tras someter los distintos algoritmos al esquema de validación temporal, el modelo **SVM-RBF** obtuvo el mejor Macro F1 promedio entre los clasificadores evaluados. No obstante, modelos como XGBoost y Random Forest también mostraron resultados competitivos, por lo que la selección del SVM-RBF se basó en su equilibrio general entre Macro F1, Balanced Accuracy y desempeño estable en los bloques temporales.

- **Rendimiento en Validación Cruzada (CV Temporal 1991-2017):** El SVM alcanzó un Macro F1-Score de **71.88 %** a lo largo de los *folds* históricos, demostrando una sólida capacidad de aprendizaje de las fronteras de decisión climática.
- **Rendimiento en Validación Temporal (2018-2021):** El Macro F1-Score fue de **68.95 %**.
- **Rendimiento en Prueba Temporal (2022-2025):** El Macro F1-Score fue de **68.80 %**.
- **Rendimiento en Holdout Espacial (2018-2025):** El Macro F1-Score fue de **63.76 %**.

La proximidad entre el rendimiento de CV (71.88 %) y las pruebas en el futuro (68.95 % y 68.80 %) sugiere que el protocolo temporal fue consistente y que el modelo mantuvo un desempeño estable al evaluarse sobre periodos no usados durante el entrenamiento.




Figura 8: Comparativa de rendimiento (Macro F1-Score) entre modelos candidatos evaluados a lo largo de los Folds Temporales.

6.3. Análisis de Matriz de Confusión y Clasificación de Amenaza

La disección del rendimiento por clases, evidenciada en la Matriz de Confusión, ratifica el éxito de la solución propuesta. El clasificador no solo diferencia con excelente precisión los meses secos ("Baja"), sino que demuestra sensibilidad ante los picos de precipitación.

Específicamente para la categoría **Amenaza Alta**, el modelo mostró una capacidad razonable para identificar meses con precipitaciones intensas. En este proyecto, una amenaza alta se define cuando el valor de `rx5day_mm` del mes objetivo supera el umbral global P_{66} calculado sobre las zonas de desarrollo. Las confusiones más frecuentes ocurren entre clases adyacentes, como Media y Alta, mientras que los errores extremos entre Alta y Baja son reducidos, aunque no inexistentes.




Figura 9: Matriz de Confusión Out-Of-Fold (CV temporal 71.88 %) del modelo SVM-RBF, evidenciando el desempeño multiclase.

6.4. Análisis de Importancia de Variables e Ingeniería Predictiva

El análisis de características mostró que la predicción no dependió únicamente de la lluvia del mes previo. Las variables más relevantes estuvieron asociadas con precipitación intensa, humedad, temperatura, presión atmosférica, estacionalidad y antecedentes históricos.

1. **Antecedentes temporales:** Variables como `rx5day_mm_lag1`, `rx5day_mm_lag11`, `r20mm_days_lag1` y `r20mm_days_lag11` aportaron información sobre el comportamiento reciente y estacional de la precipitación.
2. **Contexto meteorológico y estacional:** Variables como `relative_humidity_mean_pct`, `temperature_mean_c`, `surface_pressure_mean_hpa`, `target_month_sin` y `target_month_cos` ayudaron al modelo a reconocer condiciones atmosféricas y patrones mensuales asociados con la amenaza futura.




Figura 10: Gráfico de Información Mutua de las variables base con respecto a la variable objetivo.

7. Conclusiones e impactos

7.1. Conclusiones y Lecciones Aprendidas

El desarrollo del proyecto permitió evidenciar que la calidad de una solución de aprendizaje automático depende en gran medida de las decisiones tomadas antes del entrenamiento del modelo, especialmente en la preparación de datos, la definición de la variable objetivo, la prevención de fuga de información y el diseño del esquema de evaluación.

- **Obtención y construcción de datos:** Uno de los primeros retos fue conseguir información meteorológica útil para el modelado. Inicialmente se consideraron fuentes locales como INAMHI, pero se encontraron limitaciones de disponibilidad, continuidad histórica y formato. Por ello, se utilizó ERA5-Land como fuente principal. Sin embargo, al venir en archivos NetCDF multidimensionales, fue necesario extraer, limpiar, transformar y agregar la información hasta obtener un conjunto tabular organizado por zona y mes.
- **Definición del target:** Una dificultad importante fue definir correctamente la variable objetivo. En una versión inicial se usaban percentiles por zona y mes, pero esto medía principalmente anomalías locales y no una magnitud física comparable entre zonas. Se resolvió utilizando umbrales globales de `rx5day_mm` calculados sobre el período de desarrollo, lo que permitió clasificar la amenaza en Baja, Media y Alta bajo una misma escala.

- **Control del leakage temporal:** Se identificó que el cálculo de umbrales, la generación de rezagos, el escalado, la selección de características y el ajuste de hiperparámetros podían introducir información futura si se aplicaban incorrectamente. Para evitarlo, se usaron divisiones cronológicas, validación temporal y transformaciones dentro de *Pipeline*, respetando el orden pasado-futuro.
- **Selección de variables:** Se comprobó que utilizar más variables no necesariamente mejora el desempeño del modelo. Durante el análisis se redujo el conjunto inicial hasta trabajar con 38 características justificadas, incluyendo variables actuales, ubicación, estacionalidad y rezagos relevantes como *lag1* y *lag11*. Esto permitió priorizar variables con aporte real al modelo.
- **Evaluación del modelo:** El desempeño no se analizó únicamente mediante una métrica global. Además del *Macro F1*, se revisó el comportamiento por clase y el *recall* de la categoría Alta, debido a que los casos de mayor amenaza son especialmente relevantes dentro del problema meteorológico planteado.
- **Generalización espacial:** Una de las principales limitaciones apareció al evaluar zonas no observadas durante el entrenamiento. Aunque el rendimiento temporal se mantuvo cerca de un Macro F1 de 0.69, el holdout espacial alcanzó aproximadamente 0.638. Esto evidenció que predecir nuevos períodos en zonas conocidas es más sencillo que generalizar hacia ubicaciones completamente nuevas.

7.2. Impactos Esperados y Posibilidades Futuras

Impacto Social e Institucional: El sistema propuesto tiene el potencial de transformarse en una herramienta de alerta temprana a mediano plazo altamente escalable. Al basarse en la lectura de datos satelitales globales (ERA5-Land) e interpolados geográficamente, el modelo puede ofrecer estimaciones de amenaza para zonas rurales o selváticas de Ecuador que actualmente carecen de estaciones meteorológicas físicas in situ (como las del INAMHI). Esto impacta directamente en la planificación agrícola, la gestión de riesgos de infraestructura vial y la distribución de recursos preventivos por parte del COE Nacional.

Escalabilidad Tecnológica: Desde el punto de vista del desarrollo de software, la arquitectura modular desacoplada permite que en futuras iteraciones se reemplace el modelo estático por una inferencia basada en microservicios en la nube. Además, el pipeline permite una transición orgánica desde Machine Learning Clásico hacia arquitecturas de *Deep Learning* (como Redes Neuronales Recurrentes o Transformers Espaciotemporales) que ingieran directamente el cubo tridimensional NetCDF sin necesidad de aplanarlo, lo que potenciaría enormemente la resolución y exactitud del monitoreo climático del país.

Referencias

- [1] Copernicus Climate Change Service (C3S), “ERA5-Land monthly averaged data from 1950 to present,” *Copernicus Climate Data Store*, 2026. [Online]. Available: <https://cds.climate.copernicus.eu/>.
- [2] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.
- [3] Instituto Nacional de Meteorología e Hidrología (INAMHI), “Boletines y Anuarios Meteorológicos del Ecuador,” *INAMHI*, Quito, Ecuador, 2026. [Online]. Available: <http://www.inamhi.gob.ec/>.
- [4] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273-297, 1995.
- [5] S. Raschka and V. Mirjalili, *Python Machine Learning*, 3rd ed. Birmingham, UK: Packt Publishing, 2019.