

Escuela Superior Politécnica del Litoral
Facultad de Ingeniería en Electricidad y Computación

Inteligencia Artificial

Grupo #6

Integrantes:

Katherine Forero

David Ramírez

Anthony Herrera

Profesor:

Enrique Peláez

Fecha de Entrega:

Martes, 26 de mayo de 2026

**Aplicaciones de IA en optimización logística de última milla,
algoritmos que mejoran rutas de entrega en tiempo real
considerando tráfico, demanda y restricciones operativas.**

Solución 1: Optimización Dinámica de Rutas en Tiempo Real mediante Aprendizaje por Refuerzo Profundo

Descripción de un problema

Problema específico: Existe una brecha crítica entre la planificación teórica de rutas (basada en el problema clásico del viajero o TSP) y la ejecución real en la última milla urbana. Los despachadores suelen diseñar rutas estáticas al inicio del día. Sin embargo, las ciudades operan en entornos altamente "aleatorios", por decirlo de algún modo. Factores impredecibles como la congestión vehicular repentina, accidentes, variaciones climáticas y cambios de última hora en la disponibilidad del cliente provocan que los planes iniciales ya no sirvan a los pocos minutos de iniciar el viaje. Además, los algoritmos tradicionales ignoran el conocimiento de los conductores experimentados (saber en qué calles hay parqueo seguro, qué edificios toman más tiempo de acceso, etc.). Esto genera ineficiencia en el uso de combustible, retrasos graves en los tiempos de entrega y el incumplimiento de las ventanas horarias que se prometen.

Impacto de la solución: La implementación de un sistema de ruteo dinámico e inteligente permite abordar estos imprevistos al momento. A nivel operativo, reduce los tiempos totales de viaje hasta en un 21%, disminuye el consumo de combustible en un 13% y eleva la tasa de utilización de los vehículos de la flota en un 17%, disminuyendo en paralelo las emisiones de carbono urbanas.

Beneficiarios de la solución: Empresas de e-commerce y courier: Reducen drásticamente sus costos logísticos directos (combustible, mantenimiento y horas extra de personal).

- **Los conductores repartidores:** Reciben secuencias de entrega viables, realistas y adaptadas a su experiencia en calle, disminuyendo el estrés laboral.
- **El cliente final:** Experimenta una tasa de cumplimiento de entrega mucho mayor y ventanas de tiempo estimado de llegada muy precisas.

Descripción de la solución utilizando IA


La solución consiste en un marco tecnológico híbrido que integra la Inteligencia Artificial (IA), el Aprendizaje Autónomo (AA), Machine Learning (ML) y el Deep Learning (DL) para transformar el ruteo estático en un sistema adaptativo en tiempo real.

Machine Learning (ML) / Aprendizaje Autónomo (AA): Se utiliza para la fase de procesamiento de datos históricos. A través de algoritmos supervisados, el sistema analiza miles de rutas ejecutadas previamente por humanos. En lugar de buscar únicamente la ruta más corta geométrica, el ML "aprende" las preferencias y comportamientos reales de los conductores en zonas específicas de la ciudad, convirtiendo ese conocimiento empírico en restricciones y pesos matemáticos para el sistema.

Deep Learning (DL): Se implementan redes neuronales profundas especializadas en series temporales, específicamente arquitecturas LSTM (Long Short-Term Memory). Estas redes

procesan flujos constantes de datos masivos en tiempo real (provenientes de sensores IoT de los repartidores, GPS y reportes de tráfico externos) para predecir el comportamiento de la congestión vial en los siguientes 15, 30 y 60 minutos con un alto nivel de precisión.

Aprendizaje por Refuerzo Profundo (Deep Reinforcement Learning - DRL): Es el núcleo de la toma de decisiones dinámicas. Un agente inteligente se entrena utilizando algoritmos de aprendizaje por refuerzo combinados con redes profundas. El agente interactúa con el mapa de la ciudad, si ocurre un imprevisto (ej. un embotellamiento detectado por la red LSTM), el agente evalúa de inmediato el nuevo estado del entorno y ejecuta una acción: recalcular y reordenar la secuencia de entregas pendientes en la aplicación móvil del conductor mientras se encuentra en movimiento, maximizando y priorizando una función de recompensa basada en la menor distancia y el cumplimiento estricto del tiempo.



Organizaciones en Ecuador con interés potencial

Organizaciones objetivo: Servientrega Ecuador S.A. y Urbano Express S.A.

Justificación: Ambas compañías lideran el mercado de servicios postales, mensajería y entrega de e-commerce a nivel nacional. Operar en ciudades ecuatorianas de alta densidad como Guayaquil (con sectores complejos de alta congestión como la Av. Francisco de Orellana o la Vía a la Costa) y Quito vuelve ineficiente el ruteo estático clásico. A estas empresas les interesa de forma urgente implementar este tipo de tecnología por tres razones:

1. El control estricto de costos operativos y consumo de combustible ante la fluctuación de los precios de la gasolina en el país.
2. La necesidad de reducir la tasa de "entregas fallidas" (cuando el courier acude y el cliente no está), permitiendo coordinar y desviar la ruta de forma dinámica en base a ventanas horarias predictivas locales.
3. La presión competitiva de plataformas tecnológicas internacionales, obligándolas a digitalizar sus flotas para sostener sus márgenes de ganancia en el mercado local.

Referencias bibliográficas

Amazon Science. (2021). 2021 Amazon Last Mile Routing Research Challenge Dataset. MIT Center for Transportation and Logistics. Disponible en:

<https://registry.opendata.aws/amazon-last-mile-challenges/>

AWS Supply Chain. (2023). AWS last mile solution for faster delivery, lower costs, and a better customer experience. Amazon Web Services Blog. Disponible en:

<https://aws.amazon.com/blogs/supply-chain/aws-last-mile-solution-for-faster-delivery-lower-costs-and-a-better-customer-experience/>

World Journal of Advanced Research and Reviews. (2023). Real-Time Route Optimization in Logistics: A Deep Learning Approach. Vol. 19, No. 2, pp. 450-462. Disponible en:

https://wjarr.com/sites/default/files/fulltext_pdf/WJARR-2023-1524.pdf

MDPI Systems. (2025). A Deep Reinforcement Learning Framework for Last-Mile Delivery with Public Transport and Traffic-Aware Integration. Systems Journal, Vol. 10, No. 5.

Disponible en: <https://www.mdpi.com/2412-3811/10/5/112>

Solución 2: Asignación dinámica de pedidos a repartidores mediante Machine Learning y Optimización

Descripción de un problema

Problema específico:

En plataformas de delivery bajo demanda, el problema no consiste solamente en encontrar la mejor ruta, sino en decidir qué repartidor debe atender cada pedido. DoorDash llama a este reto el dispatch problem, que busca llevar cada pedido desde el local hasta el cliente usando al repartidor más eficiente. La dificultad está en que el sistema debe considerar varias variables: la ubicación del repartidor, la ubicación del local, el tiempo de preparación del pedido, la disponibilidad del repartidor y la posibilidad de agrupar varios pedidos en una misma entrega. DoorDash resolvió este problema usando su sistema DeepRed, basado en machine learning y optimización.

Impacto de la solución:

La solución planteada por el sistema DeepRed permite reducir retrasos, evitar que los pedidos lleguen tarde o en mal estado, mejorar las rutas de los repartidores y aumentar la satisfacción de clientes y locales. Además, ayuda a que la plataforma trabaje de forma más eficiente, asignando los pedidos con base en datos y no solo por cercanía.

Beneficiarios de la solución:

Los principales beneficiarios son:

- **Clientes:** reciben sus pedidos en menor tiempo y con mayor puntualidad.
- **Repartidores:** reciben asignaciones más accesibles y con mejores oportunidades de ganancia.
- **Locales:** reducen reclamos por demoras o entregas deficientes.
- **Plataformas de delivery:** optimizan su operación y reducen cancelaciones.

Descripción de la solución utilizando IA

La solución implementada por DoorDash consiste en un sistema llamado DeepRed, que combina machine learning y optimización matemática para decidir qué pedido debe ser ofrecido a cada repartidor. El sistema no analiza un pedido de forma aislada, sino el estado general del mercado: pedidos disponibles, repartidores activos, tiempos de preparación, distancias y posibles combinaciones de entregas.


¿En qué consiste la solución y cómo aplica estas técnicas?

Machine Learning: Se utiliza para predecir tiempos importantes dentro de la entrega, como cuánto tardará el comercio en preparar el pedido, cuánto tardará el repartidor en llegar al local y cuánto tiempo tomará entregar el pedido al cliente.

Optimización matemática: Después de obtener las predicciones, el sistema decide cuál es la mejor asignación entre pedidos y repartidores. DoorDash señala que este problema puede formularse como un modelo de programación entera mixta, usando variables binarias para representar si un repartidor será asignado o no a un pedido. Este enfoque permite optimizar la velocidad de entrega y la eficiencia del repartidor.

Simulación y experimentación: DoorDash también usa simulaciones y experimentos para probar cambios antes de aplicarlos en producción. Así puede evaluar si una nueva regla o modelo mejorará realmente el tiempo de entrega y la eficiencia del sistema.

Relación con problemas técnicos conocidos: Este caso se relaciona con el problema de asignación, donde se asignan trabajadores a tareas minimizando costos, y con el problema de pickup and delivery, donde se organizan recogidas y entregas considerando restricciones. Google OR-Tools presenta estos problemas como modelos de optimización aplicables a la logística.



Organizaciones en Ecuador con interés potencial

Organizaciones objetivo:

PedidosYa Ecuador, Rappi Ecuador y Tipti.

Justificación:

Estas organizaciones podrían tener interés en una solución similar porque operan servicios de entrega a domicilio y necesitan asignar pedidos a repartidores o shoppers de manera eficiente. En ciudades como Guayaquil o Quito, donde existen horas pico, tráfico, zonas de alta demanda y entregas simultáneas, una mala asignación puede causar retrasos, cancelaciones y reclamos. Una solución basada en IA permitiría decidir qué repartidor debe atender cada pedido considerando ubicación, disponibilidad, carga de trabajo y tiempo estimado de entrega.

Además, esta problemática también está respaldada en estudios académicos recientes sobre asignación dinámica de pedidos a couriers en servicios de entrega instantánea, donde se plantea la necesidad de generar asignaciones en tiempo real para satisfacer a proveedores, clientes y repartidores.

Referencias bibliográficas

Weinstein, A. (2021, agosto 17). Using ML and optimization to solve DoorDash's dispatch problem. DoorDash Engineering.
<https://careersatdoordash.com/blog/using-ml-and-optimization-to-solve-doordashs-dispatch-problem/>

Jin, H., Wien, J., & Lin, S. (2020, febrero 28). Next-generation optimization for Dasher dispatch at DoorDash. DoorDash Engineering.
<https://careersatdoordash.com/blog/next-generation-optimization-for-dasher-dispatch-at-door-dash/>

Jorge, D., Rocha, T., & Ramos, T. R. P. (2024). A time-driven simulation–optimization framework for the dynamic heterogeneous order-courier assignment problem for instant deliveries. *Transportation Research Part E: Logistics and Transportation Review*, 192, Article 103783. <https://doi.org/10.1016/j.tre.2024.103783>

Google for Developers. (2024, agosto 28). Vehicle routing with pickups and deliveries. Google OR-Tools. https://developers.google.com/optimization/routing/pickup_delivery

Solución 3: Reducción de Entregas Fallidas mediante Predicción de Demanda NLP y Reprogramación Autónoma

Descripción de un problema

Problema específico: Uno de los mayores cuellos de botella y generadores de costos extra ocurre cuando el repartidor llega al domicilio, pero el cliente final no se encuentra presente, la dirección indicada es demasiado compleja e imprecisa de ubicar o simplemente era la incorrecta. Esto genera las llamadas "entregas fallidas", las cuales obligan a realizar un segundo o tercer intento, desperdiciando tiempo crítico del conductor, incrementando el gasto de combustible y elevando enormemente los costos operativos.

Impacto de la solución: Al integrar herramientas de Inteligencia Artificial para predecir horarios efectivos de los clientes y facilitar la gestión dinámica de los paquetes, se reduce dramáticamente la tasa de intentos fallidos. La tecnología permite que el paquete y el usuario se comuniquen al instante, volviendo a optimizar el trayecto sobre la marcha y logrando el éxito en la entrega desde el primer intento. Esto se traduce en menor contaminación ambiental, optimización del tiempo logístico y una mejora en la satisfacción del consumidor.

Beneficiarios de la solución:

- **Empresas de logística y mensajería:** Reducen drásticamente los gastos generados por viajes en vano y disminuyen las quejas y reclamos.
- **Repartidores:** Disminuyen la frustración y el desgaste físico al no perder tiempo deambulando en la búsqueda de domicilios imprecisos o esperando a clientes que no se encuentran en la ubicación de destino.
- **Consumidores finales:** Ganan autonomía total para elegir cuándo y dónde recibir sus compras, adaptando la entrega a su estilo de vida.

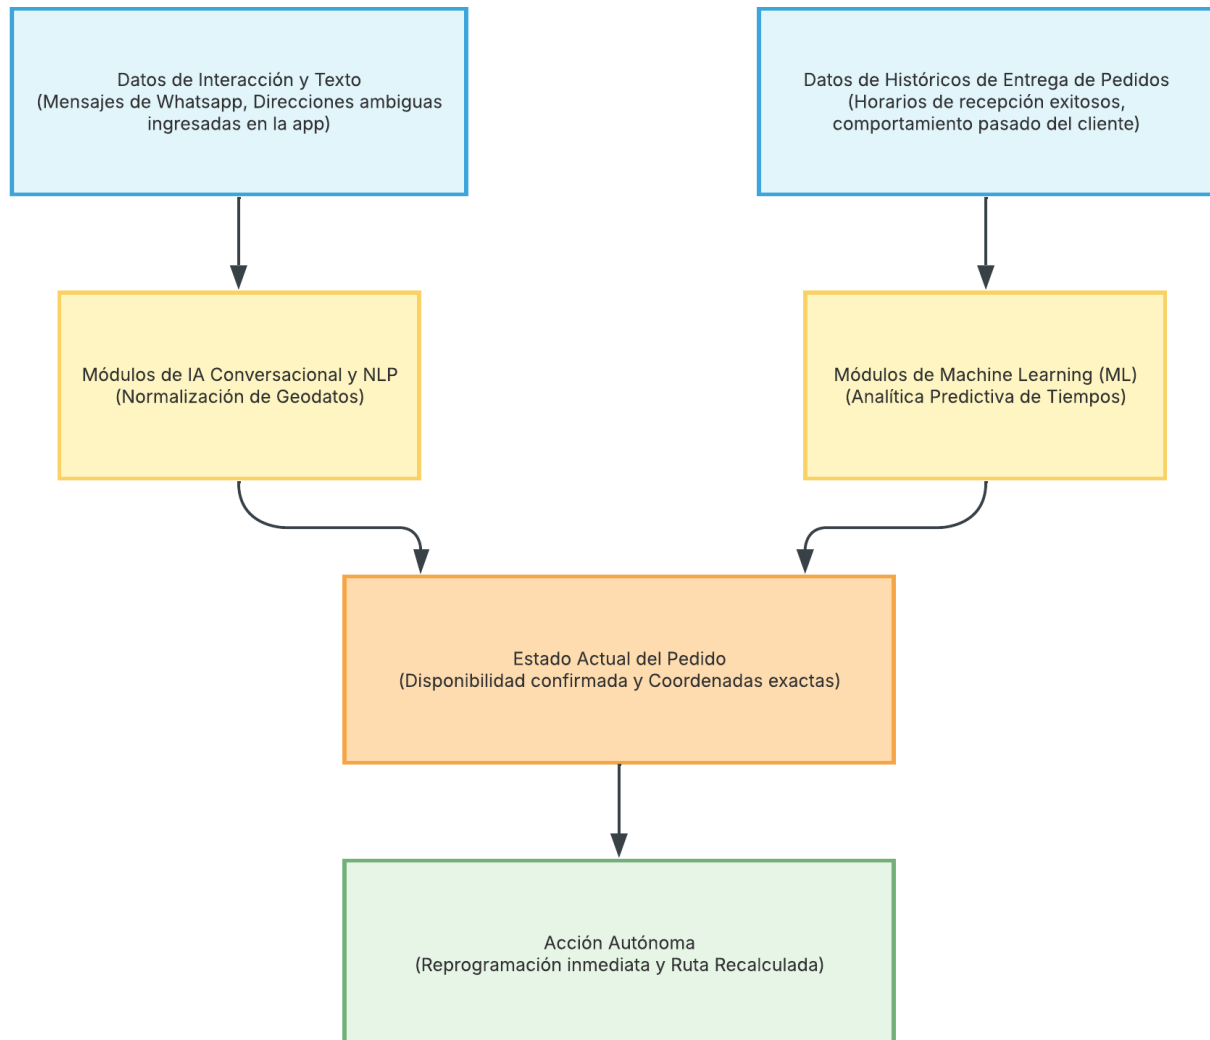
Descripción de la solución utilizando IA

La solución se centra en plataformas logísticas que combinan Big Data, la Internet de las Cosas (IoT) y algoritmos de Inteligencia Artificial para manejar el contacto directo con el consumidor.

Machine Learning (ML) para Analítica Predictiva: En lugar de simplemente planear una ruta estática, los algoritmos analizan el histórico de datos y el comportamiento del cliente para predecir con alta probabilidad qué ventana de tiempo es la más factible para encontrar a la persona en casa, anticipándose a las entregas fallidas.

IA Conversacional y Reprogramación Autónoma: Plataformas impulsadas por IA envían notificaciones predictivas y emplean chatbots (como herramientas de WhatsApp) para interactuar automática y directamente con el usuario. Si el consumidor informa que no estará en su domicilio, el sistema de IA reprograma la entrega de inmediato y recalcula dinámicamente la ruta del delivery en tiempo real para saltarse esa parada.

Procesamiento de Lenguaje Natural (NLP) para Corrección de Geodatos: La inteligencia artificial procesa y normaliza las instrucciones textuales ambiguas ingresadas por los usuarios (ej. "junto a la tienda de la esquina azul"), identificando referencias exactas en el mapa para dirigir a los repartidores hasta un margen de error de pocos metros de la puerta.



Organizaciones en Ecuador con interés potencial

- **Organizaciones objetivo:** DHL Express Ecuador, Servientrega, Tramaco Express y Urbano Express S.A.
- **Justificación:** Todas estas empresas de courier se enfrentan diariamente al grave problema de las direcciones imprecisas.. Adoptar modelos de IA predictiva e interfaces de reagendamiento automático les permitiría combatir los altos costos de la logística por paquetes no entregados, agilizando todo su ciclo de distribución para el comercio local.

Referencias bibliográficas

DHL Spain. (2023). La IA en la logística y la entrega de última milla. Recuperado de <https://www.dhl.com/discover/es-es/asesoramiento-logistico/informacion-logistica/ia-en-la-logistica-y-entrega-de-ultima-milla>

Mundo Posgrado. (s.f.). ¿Qué es la logística de última milla?. Recuperado de <https://www.mundoposgrado.com/que-es-la-logistica-de-ultima-milla/>

Ok Otto Agency. (2025). La IA de DHL que convierte el tráfico en una ventaja. Recuperado de <https://www.ok-otto.com/blog/la-ia-de-dhl-que-convierte-el-trafico-en-una-ventaja/>

The Logistics World. (2023). ¿Por qué fallan las entregas de última milla?. Recuperado de <https://thelogisticsworld.com/logistica-y-distribucion/por-que-fallan-las-entregas-de-ultima-milla/>