

Escuela Superior Politécnica del Litoral
Facultad de Ingeniería en Electricidad y Computación
Inteligencia Artificial

Título del proyecto:

Predicción del riesgo de lluvias intensas en zonas vulnerables de Ecuador
mediante modelos de aprendizaje automático usando datos meteorológicos
históricos del INAMHI

Nivel según rúbrica: Satisfactorio

Calificación: 8 / 10

Se acepta la propuesta de clasificación de riesgo bajo, medio o alto con datos oficiales del INAMHI, pero con correcciones.

La solución con modelos de ML para datos tabulares, como regresión logística, árboles, Random Forest y Gradient Boosting, es razonable. Deben concretar el objetivo. Si la etiqueta "riesgo alto/medio/bajo" se construye directamente a partir de la precipitación mensual y esa misma precipitación se usa como variable de entrada, el modelo aprenderá una regla circular y no un patrón predictivo útil.

Deben definir con cuidado qué se quiere clasificar?: riesgo del mes actual usando variables climáticas del mismo mes?, o riesgo futuro usando variables de meses anteriores?.

Si el objetivo es preventivo, deberían usar variables históricas previas, estación, mes, ubicación y rezagos de precipitación para estimar la categoría futura. También deben reemplazar los ejemplos referenciales con datos reales descargados de la fuente oficial.

El objetivo debe tener un solo verbo en infinitivo. Podría ser: "Clasificar el riesgo mensual de lluvias intensas en estaciones seleccionadas de Ecuador mediante modelos de aprendizaje automático entrenados con datos históricos del INAMHI".

En la siguiente entrega deben modelar formalmente el problema antes de diseñar la solución, definir entradas, salidas, variable objetivo, restricciones de datos, actores, flujo del sistema y criterios de evaluación. Deben mantener referencias, logs de IA y reflexión crítica. NECESITAN referencias a las fuentes, la referencia no es chatgpt

Integrantes:

Katherine Forero

David Ramírez

Anthony Herrera

Grupo #6

Profesor:

Enrique Peláez J. Ph.D.

Fecha de Entrega:

Martes, 09 de junio de 2026

Índice

Problema Propuesto.....	3
Descripción del Problema.....	3
Objetivo.....	4
Clientes o Usuarios Potenciales.....	5
Descripción Preliminar de la Solución Propuesta.....	6
Subproblema 1: Preprocesamiento de Datos.....	6
Subproblema 2: Procesamiento Usando Técnicas de IA o ML.....	6
Subproblema 3: Implementación de la Aplicación.....	7
Componentes Preliminares de la Solución.....	7
Diagrama de Bloques.....	8
Base de Datos para Entrenamiento.....	9
Ejemplo Preliminar de Datos a Utilizar Para Entrenamiento.....	9
Resultados Esperados.....	11
Referencias.....	12
Anexo de Las Sesiones Realizadas Con Chatgpt u Otra Herramienta Basada en IA.....	13
Pregunta 1.....	13
Respuesta Generada.....	13
Pregunta 2.....	13
Respuesta Generada.....	14
Pregunta 3.....	14
Respuesta Generada.....	14
Pregunta 4.....	16
Respuesta Generada.....	16
Pregunta 5.....	17
Respuesta Generada.....	17
¿Cómo se integraron las respuestas generadas por IA en la definición del problema?.....	18
Reflexión grupal sobre la utilidad de las respuestas generadas por IA.....	18
Respuestas a las Preguntas Finales.....	19
¿Agregaron sus propios criterios en la selección de los componentes y su definición, más allá de las respuestas generadas por las herramientas basadas en IA?.....	19
¿Encontraron algún beneficio o limitaciones de las herramientas?.....	19

Problema Propuesto

Riesgo de lluvias intensas en zonas vulnerables de Ecuador.

Descripción del Problema

En Ecuador, las lluvias intensas representan un problema recurrente que puede provocar inundaciones, deslizamientos, afectaciones a viviendas, interrupciones en la movilidad, daños en cultivos y riesgos para la población. Este problema es especialmente relevante en zonas vulnerables donde las condiciones geográficas, urbanas o sociales aumentan el impacto de los eventos meteorológicos extremos.

Actualmente, muchas decisiones preventivas frente a lluvias intensas dependen de reportes meteorológicos, experiencia previa o análisis manuales de información histórica. Sin embargo, el comportamiento de las precipitaciones puede variar significativamente según la zona geográfica, la época del año, la estación meteorológica, entre otras variables climáticas. Esto dificulta identificar patrones de riesgo únicamente mediante observación directa o revisión manual de datos.

El problema presenta características que justifican el uso de técnicas de Inteligencia Artificial y Aprendizaje Automático, debido a que existe una cantidad considerable de datos meteorológicos históricos que pueden contener patrones útiles para clasificar niveles de riesgo. Variables como precipitación mensual, temperatura media, temperatura máxima, temperatura mínima, ubicación de estaciones meteorológicas y periodo del año pueden ser analizadas por modelos de aprendizaje automático para encontrar relaciones que permitan estimar si una zona presenta riesgo bajo, medio o alto de lluvias intensas.

El proyecto se enfocará en el análisis de datos meteorológicos oficiales de Ecuador, principalmente del Instituto Nacional de Meteorología e Hidrología (INAMHI). El propósito no será reemplazar los sistemas oficiales de pronóstico meteorológico, sino proponer una herramienta académica basada en IA que permita clasificar preliminarmente el riesgo de lluvias intensas en zonas seleccionadas del país.

Objetivo

Desarrollar un modelo de aprendizaje automático que permita clasificar el nivel de riesgo de lluvias intensas en zonas seleccionadas de Ecuador, utilizando datos meteorológicos históricos oficiales del INAMHI, con el fin de apoyar el análisis preventivo y la toma de decisiones frente a posibles eventos de lluvia extrema.

Específicamente, lo que resolverá este proyecto será la clasificación del riesgo de lluvias intensas en categorías como bajo, medio y alto, a partir de variables meteorológicas históricas. El proyecto no buscará predecir con exactitud el clima diario, sino identificar patrones históricos que permitan estimar niveles de riesgo en determinadas zonas y periodos.

Clientes o Usuarios Potenciales

Los clientes o usuarios potenciales de este proyecto serían organizaciones e instituciones de Ecuador que trabajan en prevención, gestión de riesgos, planificación territorial o análisis climático. Entre ellas se encuentran:

- ➔ Gobiernos Autónomos Descentralizados municipales y provinciales, que podrían utilizar la información para apoyar decisiones preventivas en zonas propensas a inundaciones o deslizamientos.
- ➔ Secretaría de Gestión de Riesgos, que podría beneficiarse de una herramienta de apoyo para identificar zonas con mayor probabilidad de afectación por lluvias intensas.
- ➔ Instituto Nacional de Meteorología e Hidrología, INAMHI, como entidad técnica relacionada con la generación y difusión de información meteorológica e hidrológica en Ecuador.
- ➔ Ministerio de Agricultura y Ganadería, especialmente para zonas agrícolas donde las lluvias intensas pueden afectar cultivos, caminos rurales o actividades productivas.
- ➔ Organizaciones comunitarias y juntas parroquiales, que podrían usar resultados simplificados para fortalecer planes locales de prevención.
- ➔ Universidades e instituciones de investigación, como apoyo para estudios relacionados con cambio climático, análisis meteorológico, gestión de riesgos o aplicación de inteligencia artificial en problemas locales.

Descripción Preliminar de la Solución Propuesta

La solución propuesta consiste en desarrollar un sistema basado en aprendizaje automático que procese datos meteorológicos históricos y clasifique el nivel de riesgo de lluvias intensas en zonas seleccionadas de Ecuador.

La solución se dividirá preliminarmente en tres subproblemas principales.

Subproblema 1: Preprocesamiento de Datos

En esta etapa se recopilarán los datos meteorológicos históricos disponibles en fuentes oficiales, principalmente del INAMHI. Se utilizarán variables como precipitación total mensual, temperatura media mensual, temperatura máxima absoluta, temperatura mínima absoluta, estación meteorológica, provincia o ubicación, año y mes.

Luego, se realizará la limpieza y preparación de los datos. Esto incluirá la revisión de valores nulos, eliminación o tratamiento de registros incompletos, estandarización de nombres de estaciones, conversión de fechas, selección de variables relevantes y construcción de una variable objetivo. Esta variable objetivo representará el nivel de riesgo de lluvias intensas, por ejemplo: bajo, medio o alto.

Una posible forma de construir la variable de riesgo será comparar la precipitación mensual de una estación con umbrales definidos a partir de los datos históricos. Por ejemplo, valores bajos de precipitación se clasificarían como riesgo bajo, valores intermedios como riesgo medio y valores muy altos como riesgo alto.

Subproblema 2: Procesamiento Usando Técnicas de IA o ML

En esta etapa se entrenarán modelos de aprendizaje automático supervisado para clasificar el nivel de riesgo de lluvias intensas. Como modelos preliminares se consideran:

- Regresión logística, como modelo base de comparación.
- Árboles de decisión, para obtener una primera interpretación de las reglas de clasificación.
- Random Forest, como modelo principal debido a que funciona bien con datos tabulares y permite analizar la importancia de las variables.
- XGBoost o Gradient Boosting, como posible modelo alternativo si el volumen y calidad de datos lo permite.

El modelo recibirá como entrada variables meteorológicas y temporales, y generará como salida una categoría de riesgo: bajo, medio o alto. El desempeño del modelo será evaluado mediante métricas como exactitud, precisión, recall, F1-score y matriz de confusión.

Subproblema 3: Implementación de la Aplicación

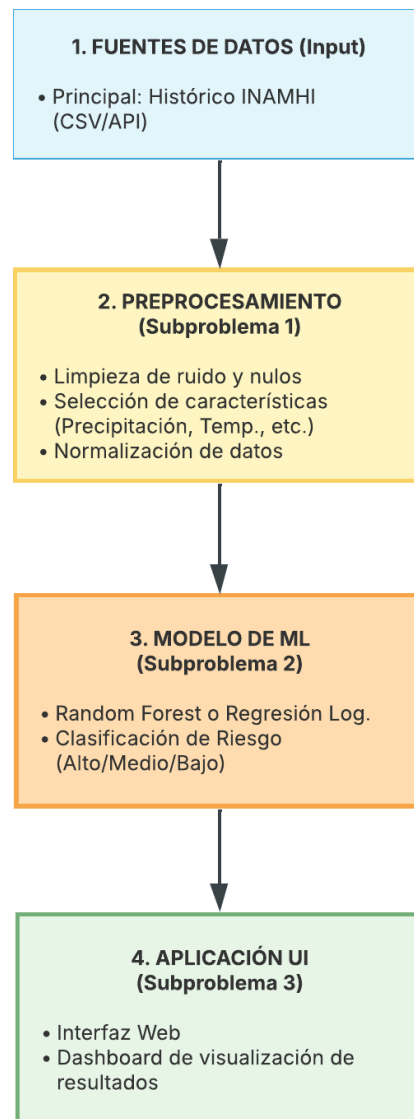
La implementación preliminar consistirá en una aplicación sencilla que permita cargar datos meteorológicos, seleccionar una estación o zona, ejecutar el modelo entrenado y mostrar el nivel de riesgo estimado.

La aplicación podría desarrollarse utilizando Python y una interfaz simple con Streamlit o Flask. También podría incluir gráficos para visualizar la precipitación histórica y la categoría de riesgo generada por el modelo.

Componentes Preliminares de la Solución

- ❖ Componente de carga de datos: Lee archivos CSV o tablas provenientes de fuentes oficiales del INAMHI.
- ❖ Componente de preprocesamiento: Limpia datos, trata valores faltantes, transforma fechas, normaliza variables y genera la variable objetivo de riesgo.
- ❖ Componente de entrenamiento: Entrena modelos de aprendizaje automático con los datos preparados.
- ❖ Componente inteligente basado en ML: Clasifica el nivel de riesgo de lluvias intensas como bajo, medio o alto.
- ❖ Componente de evaluación: Calcula métricas de desempeño del modelo y genera matriz de confusión.
- ❖ Componente de visualización: Muestra resultados en tablas, gráficos y alertas preliminares.
- ❖ Componente de aplicación: Permite al usuario consultar el riesgo estimado para una estación, zona o periodo determinado.

Diagrama de Bloques



- **Bloque 1 (Fuentes de Datos):** Representa la ingesta de la información, tomando como fuente primaria los reportes históricos estructurados en formato CSV del INAMHI.
- **Bloque 2 (Preprocesamiento):** Aquí se manejan los valores faltantes, se da formato a las fechas y se estandarizan las variables climatológicas para que el algoritmo pueda procesarlas sin errores.
- **Bloque 3 (Modelo de ML):** Recibe los datos limpios y utiliza algoritmos de clasificación clásico (*Random Forest* o Regresión Logística) para evaluar las condiciones y emitir una predicción sobre la probabilidad de lluvia intensa (Riesgo Alto, Medio o Bajo).
- **Bloque 4 (Aplicación UI):** Toma los resultados matemáticos del modelo y los transforma en gráficos o alertas visuales sencillas de entender para un usuario sin conocimientos técnicos..

Base de Datos para Entrenamiento

La base de datos para entrenamiento se construirá a partir de datos meteorológicos oficiales publicados por el Instituto Nacional de Meteorología e Hidrología, INAMHI, disponibles en el portal de Datos Abiertos Ecuador y en los anuarios meteorológicos del INAMHI.

Los datasets disponibles incluyen información de precipitación total mensual y variables de temperatura de estaciones meteorológicas a nivel nacional. Estos datos son recolectados por estaciones meteorológicas del INAMHI y publicados por instituciones oficiales del Ecuador. Para el entrenamiento inicial se utilizarán los datos estructurados disponibles en formato CSV. En caso de ampliar el histórico, se revisarán los anuarios meteorológicos oficiales, considerando que podrían requerir extracción o limpieza adicional.

Ejemplo Preliminar de Datos a Utilizar Para Entrenamiento

Estacion: Guayaquil Aeropuerto

Provincia: Guayas

Anio: 2019

Mes: Marzo

Precipitacion_Total_mm: 320.5

Temperatura_Media_C: 27.1

Temperatura_Maxima_C: 34.0

Temperatura_Minima_C: 22.4

Riesgo_Lluvia_Intensa: Alto

Estacion: Quito Izobamba

Provincia: Pichincha

Anio: 2019

Mes: Abril

Precipitacion_Total_mm: 95.2

Temperatura_Media_C: 15.8

Temperatura_Maxima_C: 24.3

Temperatura_Minima_C: 8.7

Riesgo_Lluvia_Intensa: Medio

Estacion: Manta

Provincia: Manabí

Anio: 2019

Mes: Agosto

Precipitacion_Total_mm: 12.4

Temperatura_Media_C: 25.6

Temperatura_Maxima_C: 30.1

Temperatura_Minima_C: 21.9

Riesgo_Lluvia_Intensa: Bajo

Nota: Los valores anteriores son ejemplos referenciales del formato esperado. Los valores definitivos deberán ser tomados directamente de los datasets oficiales utilizados para el entrenamiento.

Resultados Esperados

Se espera obtener un modelo de aprendizaje automático capaz de clasificar preliminarmente el riesgo de lluvias intensas en zonas seleccionadas de Ecuador, utilizando variables meteorológicas históricas.

Los posibles resultados esperados son:

- ★ Una base de datos limpia y estructurada con variables meteorológicas relevantes para el análisis.
- ★ Un modelo entrenado que clasifique el riesgo de lluvia intensa en las categorías bajo, medio y alto.
- ★ Una comparación entre modelos de clasificación para seleccionar el de mejor desempeño.
- ★ Métricas de evaluación como exactitud, precisión, recall, F1-score y matriz de confusión.
- ★ Identificación de las variables más influyentes en la clasificación del riesgo, como precipitación mensual, mes del año o temperatura.
- ★ Una aplicación preliminar que permita consultar el nivel de riesgo estimado para una zona o estación meteorológica.
- ★ Visualizaciones simples que muestren patrones históricos de precipitación y resultados del modelo.

El resultado final esperado no será un sistema oficial de pronóstico meteorológico, sino una herramienta académica de apoyo al análisis preventivo del riesgo de lluvias intensas usando técnicas de inteligencia artificial.

Comentarios del Ayudante:

La variable objetivo (la que se predecirá) se da a entender que se define manualmente con umbrales sobre la precipitación, que es la misma variable que alimenta el modelo, es decir, el modelo estaría aprendiendo a replicar una regla que ustedes ya conocen, lo cual le quita valor predictivo. Consideren usar fuentes externas. Cuantifiquen la cantidad de datos en la sección de base de datos.

Referencias

Instituto Nacional de Meteorología e Hidrología. (s. f.). Anuarios meteorológicos. INAMHI.
<https://servicios.inamhi.gob.ec/anuarios-metereologicos/>

Ministerio de Telecomunicaciones y de la Sociedad de la Información. (2021, 13 de diciembre). Precipitación Total Mensual. Datos Abiertos Ecuador.
<https://www.datosabiertos.gob.ec/dataset/precipitacion-total-mensual>

Secretaría Nacional de Gestión de Riesgos. (s. f.). Datos abiertos.
<https://www.gestionderiesgos.gob.ec/datos-abiertos/>

Secretaría Nacional de Gestión de Riesgos. (s. f.). Información de gestión de riesgos en línea.
<https://www.gestionderiesgos.gob.ec/informacion-de-gestion-de-riesgos-en-linea/>

Anexo de Las Sesiones Realizadas Con Chatgpt u Otra Herramienta Basada en IA

IA utilizada: ChatGPT

Pregunta 1

Estamos interesados en desarrollar un proyecto relacionado con lluvias y datos meteorológicos en Ecuador. Considerando que existen datos meteorológicos disponibles, ¿qué problema específico nos recomendarías abordar usando técnicas de Inteligencia Artificial o Aprendizaje Automático?

Respuesta Generada

Una opción recomendable sería desarrollar un proyecto enfocado en la clasificación del riesgo de lluvias intensas en zonas seleccionadas de Ecuador, utilizando datos meteorológicos históricos oficiales. En lugar de intentar predecir exactamente el clima diario, lo cual requeriría datos más detallados y modelos meteorológicos especializados, sería más viable construir un modelo de aprendizaje automático que clasifique el riesgo en categorías como bajo, medio y alto.

Este enfoque es adecuado porque las lluvias intensas representan un problema local relevante en Ecuador, especialmente por su relación con inundaciones, deslizamientos, afectaciones a viviendas, interrupciones de movilidad y daños en cultivos. Además, existen fuentes oficiales como el INAMHI y el portal de Datos Abiertos Ecuador, que publican datos relacionados con precipitación y temperatura de estaciones meteorológicas nacionales.

La recomendación principal sería delimitar el proyecto de la siguiente manera:

“Predicción del riesgo de lluvias intensas en zonas vulnerables de Ecuador mediante modelos de aprendizaje automático usando datos meteorológicos históricos del INAMHI.”

Este tema permite trabajar con datos locales, aplicar técnicas de aprendizaje automático y proponer una solución relacionada con un problema real del país. Además, el alcance es más manejable que intentar crear un sistema completo de pronóstico meteorológico nacional.

Pregunta 2

¿Qué organizaciones, instituciones o usuarios en Ecuador podrían estar interesados en utilizar o adquirir un modelo que clasifique el riesgo o impacto potencial de lluvias intensas?

Respuesta Generada

Los posibles interesados en un modelo de clasificación de riesgo de lluvias intensas serían principalmente instituciones relacionadas con gestión de riesgos, planificación territorial, agricultura, infraestructura y prevención de desastres.

Entre los usuarios potenciales se encuentran:

Gobiernos Autónomos Descentralizados municipales y provinciales, debido a que pueden utilizar el modelo como apoyo para identificar zonas con mayor riesgo de afectación por lluvias intensas.

Secretaría de Gestión de Riesgos, ya que podría beneficiarse de una herramienta complementaria para el análisis preventivo de eventos asociados a lluvias, inundaciones o deslizamientos.

Instituto Nacional de Meteorología e Hidrología, INAMHI, como entidad técnica relacionada con la información meteorológica e hidrológica del país.

Ministerio de Agricultura y Ganadería, porque las lluvias intensas pueden afectar cultivos, suelos, caminos rurales y actividades productivas.

Prefecturas, juntas parroquiales y organizaciones comunitarias, especialmente en zonas vulnerables donde se requiere información sencilla para apoyar planes de prevención.

Universidades e instituciones de investigación, como apoyo para estudios relacionados con inteligencia artificial, cambio climático, análisis de riesgos y datos meteorológicos.

Empresas aseguradoras, constructoras o de infraestructura también podrían estar interesadas, ya que el análisis de riesgo climático puede apoyar la evaluación de exposición ante eventos extremos.

Pregunta 3

Para este problema de clasificación del riesgo de lluvias intensas, ¿sería más adecuado utilizar Aprendizaje Automático o Aprendizaje Profundo? ¿Qué modelos recomendarías usar y por qué? Incluye una definición breve de cada modelo.

Respuesta Generada

Para este problema sería más adecuado comenzar con Aprendizaje Automático, también conocido como Machine Learning, en lugar de Aprendizaje Profundo o Deep Learning. Esto se debe a que los datos meteorológicos disponibles inicialmente son datos tabulares, como precipitación mensual, temperatura media, temperatura máxima, temperatura mínima, estación meteorológica, año y mes.

El Aprendizaje Automático es una rama de la Inteligencia Artificial que permite que un modelo aprenda patrones a partir de datos históricos para realizar predicciones o clasificaciones sobre nuevos datos. En este caso, el modelo aprendería patrones asociados a distintos niveles de riesgo de lluvias intensas.

El Aprendizaje Profundo utiliza redes neuronales con varias capas para aprender patrones complejos. Es muy útil cuando se trabaja con grandes volúmenes de datos no estructurados, como imágenes satelitales, audio, texto o secuencias muy extensas. Sin embargo, para una primera versión del proyecto, podría ser innecesariamente complejo si solo se usan datos tabulares históricos.

Modelos recomendados:

Regresión logística:

Es un modelo de clasificación que estima la probabilidad de que un registro pertenezca a una clase determinada. Aunque su nombre incluye la palabra “regresión”, se usa comúnmente para problemas de clasificación. En este proyecto podría servir como modelo base para comparar el desempeño de modelos más avanzados.

Árbol de decisión:

Es un modelo que clasifica datos mediante una estructura similar a un árbol, donde cada nodo representa una condición sobre una variable. Por ejemplo, podría dividir los datos según precipitación mensual, mes o temperatura. Su ventaja es que es fácil de interpretar.

Random Forest:

Es un modelo compuesto por varios árboles de decisión. Cada árbol genera una predicción y el modelo final combina esas predicciones para obtener un resultado más robusto. Es recomendable para este proyecto porque funciona bien con datos tabulares, reduce el riesgo de sobreajuste frente a un solo árbol y permite identificar la importancia de las variables.

Gradient Boosting o XGBoost:

Son modelos que combinan varios árboles de decisión de manera secuencial, donde cada nuevo árbol intenta corregir los errores del anterior. Pueden lograr alto desempeño en datos tabulares, aunque requieren mayor ajuste de parámetros y cuidado en la evaluación.

Red neuronal simple:

Es un modelo inspirado en el funcionamiento de neuronas artificiales conectadas en capas. Podría utilizarse si se cuenta con suficientes datos, pero no sería la primera opción para este proyecto debido a que puede ser más difícil de interpretar y requerir mayor cantidad de información para entrenar adecuadamente.

Pregunta 4

¿Cómo se puede medir el desempeño de los modelos de clasificación utilizados para estimar el riesgo de lluvias intensas? Incluye una definición breve de las métricas recomendadas.

Respuesta Generada

El desempeño de los modelos de clasificación puede medirse comparando las predicciones del modelo con las categorías reales o esperadas de riesgo. Para este proyecto, las clases podrían ser riesgo bajo, riesgo medio y riesgo alto.

Métricas recomendadas:

Exactitud o accuracy:

Mide el porcentaje total de predicciones correctas realizadas por el modelo. Es decir, indica cuántas veces el modelo clasificó correctamente el nivel de riesgo. Es útil como métrica general, pero puede ser insuficiente si las clases están desbalanceadas.

Precisión:

Mide qué proporción de los casos que el modelo clasificó como una categoría específica realmente pertenecían a esa categoría. Por ejemplo, de todos los casos que el modelo clasificó como riesgo alto, la precisión indica cuántos eran realmente de riesgo alto.

Recall o sensibilidad:

Mide qué proporción de los casos reales de una categoría fueron correctamente identificados por el modelo. En este proyecto, el recall sería especialmente importante para la clase de riesgo alto, porque sería grave que el modelo no detecte eventos de lluvia intensa.

F1-score:

Es una métrica que combina precisión y recall en un solo valor. Es útil cuando se necesita balancear ambos aspectos, especialmente si las clases no tienen la misma cantidad de datos.

Matriz de confusión:

Es una tabla que permite visualizar cuántos casos fueron clasificados correctamente y cuántos fueron confundidos con otras clases. Por ejemplo, permite identificar si el modelo está confundiendo casos de riesgo alto con riesgo medio o bajo.

Importancia de variables:

Aunque no es una métrica de desempeño directamente, permite analizar qué variables influyen más en la predicción del modelo. Por ejemplo, podría mostrar si la precipitación mensual, el mes del año o la temperatura tienen mayor peso en la clasificación del riesgo.

Pregunta 5

¿Cómo se podría implementar una aplicación para utilizar el modelo de clasificación de riesgo de lluvias intensas? ¿Qué herramientas recomendarías usar para cargar datos, entrenar modelos, evaluar resultados y presentar la información al usuario?

Respuesta Generada

La aplicación podría implementarse como un sistema sencillo dividido en componentes. El objetivo sería permitir la carga de datos meteorológicos, el procesamiento de la información, la ejecución del modelo de aprendizaje automático y la visualización del nivel de riesgo estimado.

Herramientas recomendadas:

Python:

Sería el lenguaje principal recomendado, porque cuenta con librerías especializadas para análisis de datos, aprendizaje automático y desarrollo de aplicaciones simples.

Pandas:

Permite cargar, limpiar, transformar y analizar datos en formato tabular, como archivos CSV con variables meteorológicas.

NumPy:

Sirve para realizar operaciones numéricas y cálculos sobre arreglos de datos.

Scikit-learn:

Es una librería de aprendizaje automático que permite entrenar modelos como regresión logística, árboles de decisión, Random Forest y Gradient Boosting. También permite dividir datos de entrenamiento y prueba, calcular métricas y generar matrices de confusión.

Matplotlib o Plotly:

Permiten crear gráficos para visualizar tendencias de precipitación, distribución de variables y resultados del modelo.

Streamlit:

Es una herramienta que permite crear aplicaciones web simples en Python de forma rápida. Sería útil para construir una interfaz donde el usuario pueda cargar datos, seleccionar una zona o estación y visualizar el nivel de riesgo estimado.

Flask:

También podría usarse para crear una aplicación web, aunque requiere más configuración que Streamlit. Sería útil si se desea una estructura más personalizada.

Base de datos:

Para una primera versión, se podrían usar archivos CSV. Si el proyecto crece, se podría usar SQLite o PostgreSQL para almacenar datos meteorológicos procesados y resultados del modelo.

¿Cómo se integraron las respuestas generadas por IA en la definición del problema?

Las respuestas de ChatGPT fueron utilizadas para delimitar el problema y evitar un alcance demasiado amplio. Inicialmente se consideró trabajar con lluvias en general, pero a partir de la recomendación se decidió enfocar el proyecto en la clasificación del riesgo de lluvias intensas en zonas seleccionadas de Ecuador.

También se integró la recomendación de utilizar datos oficiales del INAMHI y de no proponer un sistema de predicción climática exacta, ya que eso requeriría mayor cantidad de datos, infraestructura especializada y validación meteorológica avanzada. Por esa razón, el proyecto se enfoca en una herramienta académica de apoyo al análisis preventivo mediante aprendizaje automático.

Reflexión grupal sobre la utilidad de las respuestas generadas por IA

El uso de ChatGPT fue útil para organizar ideas, identificar un problema local, proponer posibles técnicas de aprendizaje automático y reconocer limitaciones del proyecto. Sin embargo, también se identificó que las respuestas de la herramienta debían ser revisadas con criterio, especialmente en lo relacionado con la disponibilidad real de datos. Por ello, el grupo decidió verificar fuentes oficiales antes de aceptar el tema como viable, ya que los datos son la base de todo aprendizaje.

La herramienta ayudó a estructurar el problema, pero la decisión final del alcance, las fuentes de datos y el enfoque de clasificación fue tomada por el grupo considerando los requisitos de la tarea, la disponibilidad de datos locales y la viabilidad técnica del proyecto.

Respuestas a las Preguntas Finales

¿Agregaron sus propios criterios en la selección de los componentes y su definición, más allá de las respuestas generadas por las herramientas basadas en IA?

Sí. El grupo agregó criterios propios para seleccionar y delimitar los componentes del proyecto. Aunque ChatGPT sugirió varias posibilidades, se decidió enfocar el proyecto en una clasificación de riesgo y no en una predicción exacta del clima, porque esta última opción sería más compleja y requeriría datos más detallados.

También se decidió utilizar modelos de aprendizaje automático adecuados para datos tabulares, como Random Forest, árboles de decisión y regresión logística, en lugar de usar directamente aprendizaje profundo. Esta decisión se tomó porque los datos meteorológicos disponibles inicialmente son estructurados y no necesariamente requieren redes neuronales profundas.

Además, se consideró importante que el proyecto tuviera una aplicación sencilla para mostrar los resultados, por lo que se propuso una interfaz que permita consultar el riesgo estimado y visualizar datos históricos.

¿Encontraron algún beneficio o limitaciones de las herramientas?

Sí. Entre los beneficios encontrados está que ChatGPT permitió generar ideas rápidamente, comparar enfoques posibles, estructurar el problema y proponer modelos de IA adecuados. También ayudó a identificar riesgos del proyecto, como el peligro de plantear un alcance demasiado amplio o depender de datos que podrían no estar disponibles en formato adecuado.

Entre las limitaciones se encontró que la herramienta puede sugerir ideas que parecen viables, pero que deben comprobarse con fuentes oficiales. Por ejemplo, antes de proponer el proyecto fue necesario verificar la existencia de datasets meteorológicos ecuatorianos disponibles públicamente. También se identificó que la herramienta no reemplaza el análisis del grupo, ya que las decisiones finales deben basarse en los requisitos de la tarea, la calidad de los datos y la factibilidad técnica.

Por esta razón, el grupo usó las respuestas de ChatGPT como apoyo inicial, pero no como la única fuente de decisión.