

Escuela Superior Politécnica del Litoral
Facultad de Ingeniería en Electricidad y Computación
Inteligencia Artificial

Título del proyecto:

Clasificación ~~anticipada~~ del nivel de amenaza mensual por lluvias **intensas**
del mes siguiente en zonas seleccionadas del Ecuador mediante
aprendizaje automático usando datos meteorológicos históricos

~~disponibles~~

6/10

algunos modelos todavía mezclan análisis con decisiones de implementación o de solución, por ejemplo descarga desde API de Copernicus, interpolación, percentiles 33 y 66. Esos elementos son útiles, pero deben estar claramente fuera de los modelos de análisis. Si usan casos de uso necesitan modelar por lo menos 2 escenarios por cada caso de uso. Para la siguiente entrega rehacer los modelos, deben separar mejor tres secciones: modelamiento del problema, descripción preliminar de la solución e implementación. los modelos de análisis representar temas relacionados al problema, como por ejemplo: zonas, periodos, temas meteorológicos, o clima, amenaza mensual, Los algoritmos, librerías, API, percentiles concretos y modelos predictivos deben quedar para el diseño o la solución. En la siguiente entrega deben explicar cómo se construirá la etiqueta y documentar completamente el uso de IA con prompts, respuestas y reflexión crítica, son olvidar que NO se aceptará el uso de APIs, prompts o funciones existentes que resuelvan el problema

Integrantes:

Katherine Forero

David Ramírez

Anthony Herrera

Grupo #6

Profesor:

Enrique Peláez J. Ph.D.

Fecha de Entrega:

Jueves, 09 de julio de 2026

Índice

Problema Propuesto.....	3
Descripción del Problema.....	3
Objetivo.....	4
Clientes o Usuarios Potenciales.....	5
Modelos Completos de Análisis y Definición del Problema.....	6
A. Modelo del Espacio de Estados del Problema.....	6
B. Diagrama de Flujo del Problema.....	7
Descripción Preliminar de la Solución Propuesta.....	7
Fase de extracción y preparación de datos.....	7
Fase de construcción de variables y categorías.....	8
Fase de partición temporal.....	8
Modelo de referencia: Regresión Logística Multinomial.....	8
Modelo principal: Random Forest Classifier.....	8
Evaluación e interpretación.....	9
Presentación de resultados.....	9
Diagrama de Bloques Preliminar de la Solución.....	10
Implementación.....	11
Resultados Esperados.....	11
Referencias.....	12
Anexo de Las Sesiones Realizadas Con Herramienta Basada en IA.....	13
Pregunta 1.....	13
Respuesta Generada.....	13
Pregunta 2.....	13
Respuesta Generada.....	13
Pregunta 3.....	14
Respuesta Generada.....	14
¿Cómo se integraron las respuestas generadas por IA en la definición del problema?.....	14
Reflexión grupal sobre la utilidad de las respuestas generadas por IA.....	15
Respuestas a las Preguntas Finales.....	16
¿Agregaron sus propios criterios en la selección de los componentes y su definición, más allá de las respuestas generadas por las herramientas basadas en IA?.....	16
¿Encontraron algún beneficio o limitaciones de las herramientas?.....	16

Problema Propuesto

Clasificación anticipada del nivel de amenaza por lluvias **intensas** del mes siguiente en zonas seleccionadas de Ecuador.

Descripción del Problema

Necesitan referencias ... chatgpt NO es la referencia

Lo que declaran como información del problema no es de su autoría, ... o si Uds. tienen la evidencia que indique que ese es el problema, deben mostrarla

En Ecuador, las lluvias intensas representan un problema recurrente que puede provocar inundaciones, deslizamientos, afectaciones a viviendas, interrupciones en la movilidad, daños en cultivos y riesgos para la población. Este problema es especialmente relevante en zonas vulnerables donde las condiciones geográficas, urbanas o sociales aumentan el impacto de los eventos meteorológicos extremos; Aunque las lluvias intensas pueden contribuir a inundaciones, deslizamientos y otras afectaciones, el proyecto no calculará el riesgo integral de desastre ni estimará directamente sus impactos. El alcance se limitará a clasificar la amenaza meteorológica asociada a precipitaciones intensas mediante variables climáticas históricas.

Actualmente, muchas decisiones preventivas frente a lluvias intensas dependen de reportes meteorológicos, experiencia previa o análisis manuales de información histórica. Sin embargo, el comportamiento de las precipitaciones puede variar significativamente según la zona geográfica, la época del año, la altitud, la temperatura y otros factores climáticos. Esto dificulta identificar patrones de amenaza meteorológica únicamente mediante observación directa o revisión manual de datos.

Para este proyecto se utilizarán principalmente datos de reanálisis climático ERA5-Land, disponibles en Copernicus Climate Data Store. Estos datos contienen variables meteorológicas distribuidas espacial y temporalmente, como precipitación y temperatura, y se presentan en archivos multidimensionales que relacionan tiempo, latitud y longitud. Por ello, será necesario transformar la información original en un conjunto de datos tabular adecuado para el entrenamiento de modelos de aprendizaje automático.

Una limitación importante del proyecto es que los datos climáticos disponibles no necesariamente se encuentran en un formato tabular listo para entrenamiento. En muchos casos, estos datos requieren procesos de extracción, transformación y limpieza, como selección del área geográfica de Ecuador, conversión de formatos, agregación temporal, tratamiento de valores faltantes y construcción de variables útiles para el análisis. Por ello, una parte relevante del proyecto consistirá en preparar el dataset antes de aplicar los modelos de clasificación.

El proyecto propone desarrollar una herramienta académica basada en aprendizaje automático para clasificar preliminarmente el nivel de amenaza por lluvias intensas en zonas seleccionadas de Ecuador. Para ello, se utilizarán únicamente variables meteorológicas conocidas hasta el mes de consulta, como precipitaciones anteriores, temperatura, ubicación geográfica y periodo del año. El resultado será una categoría de amenaza baja, media o alta.

Objetivo

Clasificar el nivel de amenaza por lluvias intensas del mes siguiente en zonas seleccionadas del Ecuador mediante un modelo de aprendizaje automático entrenado con datos climáticos históricos disponibles en fuentes abiertas como Copernicus Climate Data Store disponibles hasta el mes de consulta.

Clientes o Usuarios Potenciales

Los clientes o usuarios potenciales de este proyecto serían organizaciones e instituciones de Ecuador que trabajan en prevención, gestión de riesgos, planificación territorial o análisis climático. Entre ellas se encuentran:

- ➔ Gobiernos Autónomos Descentralizados municipales y provinciales, que podrían utilizar la información para apoyar decisiones preventivas en zonas propensas a inundaciones o deslizamientos.
- ➔ Secretaría de Gestión de Riesgos, que podría beneficiarse de una herramienta de apoyo para identificar zonas con mayor probabilidad de afectación por lluvias intensas.
- ➔ Instituto Nacional de Meteorología e Hidrología, INAMHI, como entidad técnica relacionada con la generación y difusión de información meteorológica e hidrológica en Ecuador.
- ➔ Ministerio de Agricultura y Ganadería, especialmente para zonas agrícolas donde las lluvias intensas pueden afectar cultivos, caminos rurales o actividades productivas.
- ➔ Organizaciones comunitarias y juntas parroquiales, que podrían usar resultados simplificados para fortalecer planes locales de prevención.
- ➔ Universidades e instituciones de investigación, como apoyo para estudios relacionados con cambio climático, análisis meteorológico, gestión de riesgos o aplicación de inteligencia artificial en problemas locales.

Modelos Completos de Análisis y Definición del Problema

Subproblemas Analizados

Para representar formalmente el problema, este se divide en tres subproblemas relacionados entre sí. La división considera la naturaleza espaciotemporal de la información meteorológica, la necesidad de anticipar el comportamiento de las precipitaciones y la forma en que los usuarios institucionales consultarían e interpretarían los resultados. En esta sección se describe únicamente el problema que debe resolverse, sin incorporar todavía algoritmos, librerías ni decisiones de implementación.

Subproblema 1: Representación espaciotemporal de la información meteorológica

La información meteorológica histórica se encuentra asociada simultáneamente a una ubicación geográfica y a un periodo determinado. Cada observación puede incluir variables como precipitación, temperatura media, temperatura máxima y temperatura mínima, vinculadas con coordenadas de latitud y longitud y con un mes específico.

El problema consiste en representar estas observaciones de manera que sea posible identificar correctamente:

- Zona geográfica a la que pertenece cada registro.
- Periodo mensual correspondiente.
- Variables meteorológicas observadas.
- Secuencia cronológica de las observaciones.
- Relación entre un mes y sus periodos anteriores.

Esta representación es necesaria porque el análisis no debe considerar las observaciones como registros aislados. La amenaza por lluvias intensas puede depender del comportamiento meteorológico previo de una misma zona y de la época del año en la que se realiza la consulta.

Por tanto, cada observación debe mantener su relación con la ubicación y con el tiempo, evitando mezclar datos pertenecientes a zonas o periodos diferentes.

Subproblema 2: Clasificación anticipada del nivel de amenaza

El segundo subproblema consiste en determinar el nivel de amenaza por lluvias intensas correspondiente al mes siguiente para una zona geográfica seleccionada.

Para una zona z y un mes de consulta t , se dispone únicamente de información meteorológica registrada hasta ese periodo. A partir de estos antecedentes se requiere establecer una categoría estimada para el mes $t+1$, la cual puede pertenecer a uno de los siguientes niveles:

$Nivel\ Amenaza = \{Baja, Media, Alta\}$

La principal restricción del problema es que la información del mes que se desea clasificar no puede utilizarse como dato de entrada. En otras palabras, la precipitación observada en el mes $t+1$ no debe formar parte de los antecedentes disponibles durante la consulta.

De manera general, el problema puede expresarse como:

$$X_{z,t} \rightarrow \hat{Y}_{z,t+1}$$

donde:

- $X_{z,t}$ representa la información meteorológica disponible para la zona z hasta el mes t ;
- $\hat{Y}_{z,t+1}$ representa el nivel de amenaza estimado para el mes siguiente.

La clasificación debe considerar que las condiciones normales de precipitación varían según la ubicación y la época del año. Por esta razón, un mismo valor de precipitación puede representar una condición habitual en una zona y una condición inusual en otra.

Subproblema 3: Consulta e interpretación del nivel de amenaza

El tercer subproblema está relacionado con la necesidad de que los usuarios institucionales puedan consultar e interpretar la información generada para una zona y un periodo determinados.

Los usuarios potenciales, como analistas climáticos, técnicos de gestión de riesgos o responsables de planificación territorial, necesitan especificar:

- Zona geográfica que desean analizar.
- Mes o periodo de referencia.
- Tipo de información meteorológica que desean revisar.

Como resultado de la consulta, el usuario debe poder conocer:

- Nivel de amenaza estimado para el mes siguiente.
- Información histórica asociada con la zona consultada.
- Periodo al que corresponde la clasificación.
- Disponibilidad o insuficiencia de datos.
- Grado de confianza o las probabilidades asociadas a las categorías, cuando corresponda.

El resultado debe presentarse de manera comprensible, de modo que el usuario pueda distinguir entre una amenaza baja, media o alta sin necesidad de interpretar directamente estructuras meteorológicas complejas.

Cuando no exista información histórica suficiente para una zona o período, la consulta deberá identificarse como información insuficiente, evitando presentar una clasificación sin respaldo adecuado.

Diagrama UML de Casos de Uso

El diagrama de casos de uso representa las necesidades de los usuarios institucionales que requieren consultar el nivel de amenaza por lluvias intensas del mes siguiente para una zona geográfica determinada. Se identifican dos actores principales: el analista técnico de información climática y el responsable de planificación o gestión de riesgos. Ambos actores utilizan la información como apoyo para el análisis y la planificación, sin que el resultado constituya una alerta meteorológica oficial.




Diagrama UML de Actividades

El diagrama de actividades describe la secuencia lógica de pasos requerida para transformar las lecturas climáticas crudas en información de riesgo estructurada. El flujo inicia con la conexión automatizada y descarga de variables mensuales de precipitación y temperatura desde la API de Copernicus. Posteriormente, el proceso contempla una bifurcación para corregir posibles registros faltantes mediante interpolación antes de agrupar los datos históricamente. Finalmente, se aplican los umbrales estadísticos de los percentiles 33 y 66 para clasificar automáticamente cada registro en los niveles discretos de riesgo bajo, medio o alto, culminando con la consolidación de la matriz final de datos.

y cómo llevas estas actividades que realizan los humanos para ser resueltas con IA?
esa representación es la que deben modelar usando lenguaje formal... no estas activiades




Diagrama UML de Clases del Dominio

El diagrama de clases del dominio representa las entidades conceptuales relacionadas con la consulta del nivel de amenaza por lluvias intensas. El modelo identifica a los usuarios institucionales, las zonas geográficas, los periodos mensuales, las observaciones meteorológicas, los antecedentes históricos utilizados en una consulta y la clasificación obtenida. Su propósito es describir la estructura de la información y las relaciones del problema, sin incorporar detalles de diseño o implementación.





Diagrama UML de Máquina de Estados

El diagrama de actividades describe la secuencia lógica de pasos requerida para transformar las lecturas climáticas crudas en información de riesgo estructurada. El flujo inicia con la conexión automatizada y descarga de variables mensuales de precipitación y temperatura desde la API de Copernicus. Posteriormente, el proceso contempla una bifurcación para corregir posibles registros faltantes mediante interpolación antes de agrupar los datos históricamente. Finalmente, se aplican los umbrales estadísticos de los percentiles 33 y 66 para clasificar automáticamente cada registro en los niveles discretos de riesgo bajo, medio o alto, culminando con la consolidación de la matriz final de datos.



Descripción Preliminar de la Solución Propuesta

La solución propuesta consistirá en desarrollar un prototipo basado en aprendizaje automático supervisado para clasificar el nivel de amenaza por lluvias intensas del mes siguiente en zonas seleccionadas del Ecuador. El problema se abordará como una tarea de clasificación multiclase, en la cual la salida corresponderá a una de tres categorías: amenaza baja, media o alta.

Para efectuar la clasificación anticipada, el modelo utilizará únicamente información meteorológica disponible hasta el mes de consulta. Por ejemplo, las observaciones de una zona correspondientes al mes actual y a meses anteriores se utilizarán para estimar la categoría de amenaza del mes siguiente. De esta forma, la precipitación del periodo que se busca clasificar no será utilizada como variable de entrada.

Fase de extracción y preparación de datos

Los datos meteorológicos históricos se obtendrán principalmente del conjunto ERA5-Land disponible en Copernicus Climate Data Store. Debido a que esta información se presenta en archivos NetCDF organizados mediante dimensiones de tiempo, latitud y longitud, primero se seleccionará el área geográfica correspondiente al Ecuador y se extraerán las variables meteorológicas requeridas.

Posteriormente, los datos multidimensionales serán transformados en una estructura tabular en la que cada registro represente una zona geográfica y un periodo mensual. Durante esta fase también se realizará la revisión de valores faltantes, conversión de unidades, verificación de fechas y selección de las variables relevantes.

Fase de construcción de variables y categorías

A partir de los datos procesados se generarán variables temporales que representen las condiciones meteorológicas conocidas antes del periodo que se desea clasificar. Entre las variables preliminares se considerarán la precipitación de meses anteriores, temperatura media, temperatura máxima, temperatura mínima, mes del año, latitud y longitud de la zona analizada.

La variable objetivo representará el nivel de amenaza por lluvias intensas del mes siguiente. Su categoría se construirá a partir de la distribución histórica de la precipitación observada para cada zona y periodo del año, utilizando umbrales estadísticos calculados únicamente con los datos de entrenamiento. De esta manera, se evitará incorporar información del conjunto de prueba durante la construcción de las etiquetas.

Fase de partición temporal

Debido a que los datos corresponden a una serie histórica, la división del conjunto de datos se realizará de forma cronológica y no aleatoria. Los periodos iniciales se utilizarán para

entrenar los modelos, un periodo posterior se empleará para validación y los años más recientes se reservarán para la evaluación final.

Esta división permitirá simular el funcionamiento real de la solución, en el que los datos meteorológicos pasados se utilizan para clasificar periodos posteriores.

Reg. Log. y R.F. no es suficiente para proyecto de fin de curso

Modelo de referencia: Regresión Logística Multinomial

Necesitan comparar por lo menos 5 otros modelos y escoger el mejor para implementar en la interfaz.

Se implementará una Regresión Logística Multinomial como modelo de referencia. Este algoritmo permitirá establecer un punto inicial de comparación debido a que representa relaciones lineales entre las variables de entrada y las probabilidades de pertenencia a cada categoría.

Su desempeño permitirá determinar si un modelo de mayor complejidad proporciona una mejora relevante en la clasificación de la amenaza.

Modelo principal: Random Forest Classifier

Como modelo principal se utilizará Random Forest, un algoritmo de ensamble compuesto por múltiples árboles de decisión entrenados con diferentes muestras de datos y subconjuntos de variables.

Este modelo se considera apropiado porque puede representar relaciones no lineales entre las variables meteorológicas y manejar datos tabulares con características de distinta naturaleza. También permite estimar la importancia de las variables, lo que contribuirá a interpretar qué factores tienen mayor influencia en la clasificación.

El número de árboles, la profundidad máxima y otros hiperparámetros serán ajustados utilizando el conjunto de validación. La selección final del modelo se realizará comparando su desempeño con el de la Regresión Logística Multinomial.

Evaluación e interpretación

Los modelos se evaluarán utilizando métricas adecuadas para clasificación multiclase, como F1-score macro, exactitud balanceada, precisión, recall por categoría y matriz de confusión. Se prestará especial atención al recall correspondiente a la categoría de amenaza alta, debido a que esta métrica permitirá conocer qué proporción de los periodos de precipitación intensa fue identificada correctamente.


Además, se analizará la importancia de las variables del modelo Random Forest y se revisarán los errores de clasificación, especialmente los casos en que una amenaza alta sea clasificada como media o baja.

Presentación de resultados

El modelo seleccionado será integrado en un prototipo web académico. El usuario podrá seleccionar una zona geográfica y un periodo, consultar la categoría de amenaza estimada para el mes siguiente y visualizar información complementaria, como las probabilidades asociadas a cada categoría y los antecedentes meteorológicos utilizados en la consulta.

El prototipo tendrá un propósito académico y de apoyo al análisis. No buscará sustituir los sistemas oficiales de pronóstico meteorológico ni emitir alertas oficiales de emergencia.

Diagrama de Bloques Preliminar de la Solución



dónde está la parte inteligente?

Implementación

- Lenguaje de programación: Python 3.10 o superior, debido a su disponibilidad de librerías para el procesamiento de datos climáticos, aprendizaje automático y desarrollo de aplicaciones web.
- Entorno de desarrollo: Jupyter Notebook para la exploración, transformación y análisis de los datos, así como para el entrenamiento y evaluación de los modelos de aprendizaje automático.
- Lectura y procesamiento de datos climáticos: xarray y netCDF4 para abrir, explorar y transformar los archivos NetCDF obtenidos de ERA5-Land. Estas librerías permitirán trabajar con las dimensiones de tiempo, latitud y longitud, seleccionar el área correspondiente a Ecuador y extraer las variables meteorológicas necesarias.
- Procesamiento tabular y numérico: pandas y NumPy para limpiar los datos, tratar valores faltantes, transformar unidades, convertir la información multidimensional en una estructura tabular y construir las variables de entrada y la variable objetivo.
- Aprendizaje automático: scikit-learn para implementar los modelos de Regresión Logística Multinomial y Random Forest, realizar la partición cronológica de los datos, ajustar los hiperparámetros y calcular métricas de evaluación como precisión, recall, F1-score, exactitud balanceada y matriz de confusión.
- Visualización de resultados: Plotly para representar gráficamente las series históricas de precipitación, las probabilidades generadas por los modelos y los resultados de la clasificación.
- Interfaz de usuario: Streamlit para desarrollar un prototipo web académico que permita seleccionar una zona y un periodo, consultar el nivel de amenaza estimado y visualizar los resultados obtenidos.

Resultados Esperados

Se espera obtener un conjunto de datos meteorológicos estructurado a partir de los archivos obtenidos de datos públicos históricos disponibles, en el cual cada registro represente una zona geográfica y un periodo mensual. También se espera entrenar y comparar un modelo de regresión logística multinomial y un modelo Random Forest para clasificar el nivel de amenaza por lluvias intensas del mes siguiente en las categorías baja, media y alta.

El desempeño se evaluará mediante una partición cronológica de los datos y métricas como F1-score macro, exactitud balanceada, precisión, recall por categoría y matriz de confusión. Se prestará especial atención al recall de la categoría de amenaza alta, debido a que interesa conocer cuántos periodos de precipitación intensa son correctamente identificados.

Finalmente, se espera desarrollar un prototipo web que permita seleccionar una zona y un periodo, visualizar la categoría estimada, las probabilidades generadas por el modelo y los antecedentes meteorológicos utilizados en la consulta.

Comentarios del Ayudante:

Verificar el diagrama de casos de uso este correctamente realizado, no centralicen todo a un caso de uso, y que de ahí salgan varios include, extend. Tengan cuidado y no mezclen la solución con el problema (como con el diagrama de actividades)

Referencias

- [1] J. Muñoz-Sabater, “ERA5-Land monthly averaged data from 1950 to present,” Copernicus Climate Change Service (C3S) Climate Data Store, 2019, doi: 10.24381/cds.68d2bb30. [Online]. Available: <https://cds.climate.copernicus.eu/datasets/reanalysis-era5-land-monthly-means>. [Accessed: Jul. 9, 2026].
- [2] J. Muñoz-Sabater et al., “ERA5-Land: A state-of-the-art global reanalysis dataset for land applications,” *Earth System Science Data*, vol. 13, pp. 4349–4383, 2021, doi: 10.5194/essd-13-4349-2021.
- [3] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, Oct. 2001, doi: 10.1023/A:1010933404324.
- [4] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York, NY, USA: Springer, 2009, doi: 10.1007/978-0-387-84858-7.
- [5] F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [6] S. Hoyer and J. Hamman, “xarray: N-D labeled arrays and datasets in Python,” *Journal of Open Research Software*, vol. 5, no. 1, Art. no. 10, 2017, doi: 10.5334/jors.148.
- [7] United Nations Office for Disaster Risk Reduction, “Hazard,” Sendai Framework Terminology on Disaster Risk Reduction. [Online]. Available: <https://www.undrr.org/terminology/hazard>. [Accessed: Jul. 9, 2026].
- [8] Unidata, “netCDF4 API documentation.” [Online]. Available: <https://unidata.github.io/netcdf4-python/>. [Accessed: Jul. 9, 2026].

Anexo de Las Sesiones Realizadas Con Herramienta Basada en IA

IA utilizada: Gemini

Pregunta 1

Estamos trabajando en el proyecto de fin de curso sobre riesgo de lluvias en Ecuador. Decidimos usar el dataset de reanálisis ERA5-Land de Copernicus para todo el análisis, reemplazando fuentes locales. ¿Qué tipo de aprendizaje deberíamos usar en este caso y cómo resolvemos la falta de etiquetas para las categorías de riesgo?

Respuesta Generada

Es una decisión técnica muy sólida. Al usar únicamente datos de reanálisis de Copernicus (ERA5-Land), eliminan la complejidad de integrar múltiples fuentes y trabajan con un dataset global, consistente y de alta resolución. Siguen estando ante un problema de Aprendizaje Supervisado. La falta de etiquetas no es un problema: ustedes aplicarán ingeniería de características (Feature Engineering) para generar su propia variable objetivo Y. Al procesar la serie histórica de precipitación del dataset de Copernicus, ustedes crearán etiquetas basadas en umbrales estadísticos (ej. percentiles). Esto es un proceso estándar en proyectos de IA aplicada: transformar datos crudos en un problema de clasificación supervisada mediante criterios estadísticos propios del equipo.

Pregunta 2

Para la sección de diseño de la solución, estamos con la ligera duda si incluir Random Forest y Regresión Logística. ¿Cómo se justificaría el por qué usamos ambos y cuál es el rol de cada uno?

Respuesta Generada

Es una duda muy buena y, la verdad, es una excelente jugada metodológica! Miren, si solo proponen el Random Forest, el profesor les va a preguntar: '¿Por qué no algo más simple?'. Y ahí es donde entra la Regresión Logística Multinomial como su baseline o modelo base.

El razonamiento para justificar ambos debería ser este:

Primero, la Regresión Logística es su modelo de control. Es simple, es lineal y les va a dar un 'punto de partida' de precisión. En ingeniería, es fundamental establecer un estándar; si su modelo de IA avanzado no es capaz de superar a un método estadístico básico, entonces no se justifica la complejidad técnica.

Segundo, el Random Forest es su 'arma principal'. Los datos de Copernicus, como sabrán, tienen mucha variabilidad y ruido. El Random Forest, al crear un bosque de árboles de decisión, puede encontrar patrones más enredados y no lineales que la regresión no vería.

Digan que están usando la Regresión Logística para establecer un 'umbral de rendimiento mínimo' (baseline) y que el Random Forest es la propuesta de valor, justificada precisamente por su capacidad superior para manejar la naturaleza caótica y no lineal de los datos climáticos. Si demuestran que el Random Forest tiene un mejor Recall o Accuracy que la regresión, ya tienen la justificación técnica blindada para la defensa del proyecto ante el profesor.

Pregunta 3

Estamos armando el flujo de datos para clasificar el riesgo de lluvias usando solo Copernicus (ERA5-Land). Se nos complica un poco definir cómo pasar de datos crudos temperatura/precipitación a una etiqueta de riesgo 'Bajo, Medio o Alto'. ¿Qué enfoque nos recomiendan para que la etiqueta no sea algo arbitrario y tenga validez?

Respuesta Generada

¡Esa duda es fundamental y los pone en el camino correcto de la ingeniería de datos! Lo peor que podrían hacer es inventar los umbrales al ojo. Lo que deben hacer es aplicar un análisis de Distribución Estadística Histórica.

No lo vean como una etiqueta arbitraria, véanlo como una normalización basada en percentiles. La recomendación es: tomen la serie de tiempo histórica de cada estación (por ejemplo, los últimos 30 años de datos de Copernicus para ese punto específico) y calculen el percentil 33 y el percentil 66 de la precipitación acumulada mensual.

- Si un mes está por debajo del percentil 33, estadísticamente es un valor bajo.
- Si cae entre el 33 y el 66, es el comportamiento promedio (Medio).
- Si supera el percentil 66, ahí es donde clasifican el riesgo como 'Alto'.

Al hacer esto, no están 'inventando' etiquetas, están descubriendo umbrales de criticidad basados en el comportamiento histórico real de cada zona. Esto es mucho más robusto que poner valores fijos (como 'más de 100mm') porque el modelo se adapta automáticamente a si una zona es naturalmente seca o lluviosa. Es un enfoque analítico mucho más profesional y justificado

Pregunta 4

Para representar formalmente el problema de clasificación anticipada de amenaza por lluvias intensas, ¿qué modelos UML serían adecuados si un diagrama de casos de uso no es suficiente?

Respuesta Generada

Se recomienda utilizar varios modelos complementarios, debido a que cada uno representa un aspecto diferente del problema:

- Un **diagrama de casos de uso** para identificar a los usuarios y las necesidades que buscan satisfacer.
- Un **diagrama de actividades** para representar el flujo de una consulta desde la selección de la zona hasta la presentación del resultado.
- Un **diagrama de clases del dominio** para mostrar las entidades conceptuales del problema, sus atributos y relaciones.
- Un **diagrama de máquina de estados** para representar los posibles estados de una consulta de amenaza.
- Una **especificación matemática** para formalizar las entradas, la salida, el horizonte temporal y las restricciones del problema.

No se recomienda incluir todavía diagramas de componentes, despliegue o arquitectura técnica, debido a que estos corresponden al diseño de la solución y no al análisis del problema.

Pregunta 5

¿Cuáles deberían ser los actores principales del diagrama de casos de uso y qué elementos no deben considerarse actores?

Respuesta Generada

Los actores principales pueden ser:

1. **Analista técnico de información climática**, quien necesita consultar antecedentes meteorológicos, revisar el nivel de confianza y analizar los resultados con mayor detalle.
2. **Responsable de planificación o gestión de riesgos**, quien requiere consultar el nivel de amenaza y utilizar un reporte resumido como apoyo para la planificación.

No deben considerarse actores:

- el sistema;
- el modelo de aprendizaje automático;
- Random Forest;
- el desarrollador;
- la base de datos;
- Copernicus;
- el administrador del sistema.

Un actor debe ser una persona, organización o sistema externo que interactúe con la aplicación para alcanzar un objetivo. El sistema analizado no puede ser actor de sí mismo.

Pregunta 6

¿Qué clases conceptuales deberían aparecer en el diagrama de clases del dominio?

Respuesta Generada

Las clases principales del dominio pueden ser:

- UsuarioInstitucional
- AnalistaTecnico
- ResponsablePlanificacion
- ZonaGeografica
- PeriodoMensual
- ObservacionMeteorologica
- VentanaHistorica
- ConsultaAmenaza
- ClasificacionAmenaza

También pueden utilizarse las enumeraciones:

- NivelAmenaza, con los valores baja, media y alta;
- EstadoConsulta, con los valores pendiente, completada e información insuficiente.

Las relaciones principales indican que un usuario realiza consultas, cada consulta selecciona una zona y un periodo, utiliza una ventana histórica y puede producir una clasificación. La clasificación puede no existir cuando la información histórica sea insuficiente.

El diagrama no debe contener clases técnicas como RandomForest, DataFrame, ArchivoNetCDF, StreamlitApp o BaseDeDatos, debido a que estas pertenecen al diseño o implementación de la solución.

Pregunta 7

¿Qué flujo debería representar el diagrama de actividades?

Respuesta Generada

El flujo puede comenzar cuando el usuario selecciona una zona geográfica y un periodo de referencia. Después se solicita la consulta y se verifica si existe información histórica suficiente.

Si la información es insuficiente, se informa esta condición y el usuario puede modificar la zona o el periodo, o finalizar la consulta sin resultado.

Si la información es suficiente, se establece el mes siguiente como periodo objetivo, se obtiene una categoría de amenaza y se presenta el resultado. Posteriormente, el usuario puede consultar antecedentes meteorológicos, revisar el nivel de confianza o generar un reporte.

El diagrama debe mostrar acciones, decisiones, condiciones y resultados, pero no debe incluir procedimientos técnicos como lectura de archivos NetCDF, entrenamiento de Random Forest o ejecución de código en Python.

¿Cómo se integraron las respuestas generadas por IA en la definición del problema?

Primero, nos ayudó a traducir nuestra idea inicial de "predecir lluvias" a un problema formal de "clasificación de riesgos", asegurando que el objetivo cumpliera con el requisito de tener un solo objetivo principal. Luego, usamos las sesiones para estructurar el modelo de estados, ya que estábamos confundiendo "diseño de solución" con "análisis del problema". Gemini nos permitió identificar esta mezcla y separar correctamente qué es la definición del fenómeno climático (variables de entrada y etiquetas) de la técnica de IA que usaremos después.

Reflexión grupal sobre la utilidad de las respuestas generadas por IA

Una de las cosas que más nos ayudó fue definir cómo formalizar el problema. Al principio estábamos perdidos intentando escribir fórmulas, y la herramienta nos aclaró que podíamos usar un enfoque de "diccionario de datos" mucho más simple que nos servía igual para modelar el problema sin complicarnos la vida. También nos ayudó bastante a decidir que reemplazaríamos las fuentes locales por el dataset de Copernicus; estábamos dudando si era mejor mezclar las dos fuentes o quedarnos solo con una, y al analizarlo con la herramienta nos dimos cuenta de que usar solo Copernicus nos daba una consistencia de datos mucho más profesional para un proyecto de IA.

Respuestas a las Preguntas Finales

¿Agregaron sus propios criterios en la selección de los componentes y su definición, más allá de las respuestas generadas por las herramientas basadas en IA?

Sí. El grupo agregó criterios propios para seleccionar y delimitar los componentes del proyecto. Aunque ChatGPT sugirió varias posibilidades, se decidió enfocar el proyecto en una clasificación de riesgo y no en una predicción exacta del clima, porque esta última opción sería más compleja y requeriría datos más detallados.

También se decidió utilizar modelos de aprendizaje automático adecuados para datos tabulares, como Random Forest, árboles de decisión y regresión logística, en lugar de usar directamente aprendizaje profundo. Esta decisión se tomó porque los datos meteorológicos disponibles inicialmente son estructurados y no necesariamente requieren redes neuronales profundas.

Además, se consideró importante que el proyecto tuviera una aplicación sencilla para mostrar los resultados, por lo que se propuso una interfaz que permita consultar el riesgo estimado y visualizar datos históricos.

¿Encontraron algún beneficio o limitaciones de las herramientas?

Sí. Entre los beneficios encontrados está que ChatGPT permitió generar ideas rápidamente, comparar enfoques posibles, estructurar el problema y proponer modelos de IA adecuados. También ayudó a identificar riesgos del proyecto, como el peligro de plantear un alcance demasiado amplio o depender de datos que podrían no estar disponibles en formato adecuado.

Entre las limitaciones se encontró que la herramienta puede sugerir ideas que parecen viables, pero que deben comprobarse con fuentes oficiales. Por ejemplo, antes de proponer el proyecto fue necesario verificar la existencia de datasets meteorológicos ecuatorianos disponibles públicamente. También se identificó que la herramienta no reemplaza el análisis del grupo, ya que las decisiones finales deben basarse en los requisitos de la tarea, la calidad de los datos y la factibilidad técnica.

Por esta razón, el grupo usó las respuestas de ChatGPT como apoyo inicial, pero no como la única fuente de decisión.