

Escuela Superior Politécnica del Litoral
Facultad de Ingeniería en Electricidad y Computación
Inteligencia Artificial

Título del proyecto:

Clasificación del nivel de amenaza meteorológica por precipitación para el mes siguiente en zonas seleccionadas del Ecuador mediante aprendizaje automático a partir de datos meteorológicos históricos

Integrantes:

Katherine Forero

David Ramírez

Anthony Herrera

Grupo #6

Profesor:

Enrique Peláez J. Ph.D.

Fecha de Entrega:

Martes, 28 de julio de 2026

Índice

Problema Propuesto.....	4
Descripción del Problema.....	4
Objetivo.....	5
Usuarios Potenciales.....	5
Modelos corregidos de análisis y definición del problema.....	6
Datos y parámetros fundamentales del problema.....	6
Modelo del flujo de trabajo actual.....	6
Modelo de actores y necesidades.....	8
Modelado de Requerimientos Funcionales y Casos de uso.....	8
Diagrama UML de casos de uso.....	8
Caso de uso 1.....	8
Caso de uso 2.....	9
Caso de uso 3.....	9
Modelos completos de diseño de la solución.....	11
Descripción general de la solución.....	11
Proceso de entrenamiento y selección.....	11
Proceso de inferencia.....	12
Diagrama general de arquitectura.....	12
A. Repositorio meteorológico.....	13
B. Módulo de preparación de características.....	13
C. Gestor de particiones.....	13
D. Motor de entrenamiento y comparación.....	14
E. Selector de modelo.....	14
F. Servicio de inferencia y presentación.....	14
Diagrama de secuencia.....	15
Arquitectura del modelo principal: Random Forest.....	16
5.3.1 Entrada del modelo.....	16
5.3.2 Construcción del bosque.....	17
5.3.3 Agregación de predicciones.....	17
5.3.4 Justificación del modelo principal.....	17
Algoritmos que serán comparados.....	18
Criterio de selección.....	19
Implementación preliminar.....	20
Plataforma y lenguaje de programación.....	20
Fuente y preparación de los datos.....	20
• Recorte espacial (Clipping): Filtrar únicamente el Bounding Box correspondiente al territorio continental del Ecuador.....	20
Variables de entrada y variable objetivo.....	20
Variables de entrada ($X_{z,t}$).....	20
Variable objetivo ($Y_{z,t+1}$).....	20
Construcción de la etiqueta histórica.....	21
Librerías y herramientas.....	21

• Procesamiento Geoespacial y Extracción.....	21
• Manipulación Tabular.....	21
• Modelado Predictivo.....	21
• Visualización.....	21
• Persistencia y Despliegue.....	21
Resultados esperados.....	22
Posibilidades futuras.....	23
Referencias.....	24
Anexo de sesiones realizadas con herramientas de IA.....	25
Preguntas formuladas y respuestas obtenidas.....	25
Integración de las respuestas en el diseño.....	25
Reflexión grupal sobre la utilidad de la IA.....	25
Respuestas a las preguntas finales.....	25

Problema Propuesto

Clasificación anticipada del nivel de amenaza por lluvias del mes siguiente en zonas seleccionadas de Ecuador.

Descripción del Problema

En Ecuador, las precipitaciones pueden ocasionar eventos adversos como inundaciones, deslizamientos, lluvias intensas y erosión hídrica, con afectaciones sobre la población, las viviendas, la infraestructura y las actividades productivas. Según el SitRep nacional n.º 130 de la Secretaría Nacional de Gestión de Riesgos, entre el 1 de enero y el 10 de julio de 2026 se registraron 3.027 eventos adversos asociados a lluvias, distribuidos en las 24 provincias, 208 cantones y 796 parroquias del país [1]. Estas cifras evidencian la importancia de estudiar el comportamiento de las precipitaciones y de desarrollar herramientas complementarias que permitan analizar anticipadamente sus condiciones.

El comportamiento de la precipitación puede variar espacial y temporalmente según las características geográficas de cada zona. Estudios realizados en los Andes del sur del Ecuador han identificado diferencias importantes en los regímenes de precipitación y en los ciclos meteorológicos, relacionadas con factores como la altitud, la topografía, la época del año y los patrones atmosféricos [2], [3]. Por esta razón, un mismo volumen mensual de precipitación puede representar una condición habitual en una zona y una condición anómala en otra, por lo que no resulta adecuado utilizar un único valor fijo para clasificar todas las regiones y periodos del año.

El problema específico consiste en determinar, para una zona geográfica seleccionada y un mes de consulta t , si el nivel de amenaza meteorológica asociado a la precipitación del mes siguiente $t + 1$ corresponderá a una categoría baja, media o alta. La clasificación deberá realizarse utilizando exclusivamente información disponible hasta el mes de consulta, como las condiciones meteorológicas de los meses anteriores, el periodo del año y la ubicación geográfica. La precipitación observada durante el mes siguiente no será conocida en el momento de efectuar la estimación, por lo que el modelo deberá inferir su categoría a partir de los antecedentes disponibles.

De manera general, el problema puede expresarse mediante la relación:

$$X_{z,t} \rightarrow Y_{z,t+1}$$

donde $X_{z,t}$ representa el conjunto de información meteorológica disponible para la zona z hasta el mes t , mientras que $Y_{z,t+1}$ representa la categoría de amenaza meteorológica correspondiente al mes siguiente. La salida pertenece a una de las siguientes categorías:

$$Y_{z,t+1} \in \{\text{Baja, Media, Alta}\}$$

El problema será abordado como una tarea de aprendizaje automático supervisado de clasificación multiclase. A partir de registros meteorológicos históricos, los modelos deberán aprender las relaciones existentes entre las condiciones conocidas hasta un periodo determinado y la categoría observada durante el periodo siguiente. Por tanto, la función del aprendizaje automático será estimar una categoría futura a partir de antecedentes meteorológicos, y no simplemente clasificar un mes utilizando la precipitación ya observada durante ese mismo periodo.

Las categorías baja, media y alta representarán el comportamiento de la precipitación respecto a las condiciones históricas de cada zona y periodo del año. Los registros históricos permitirán establecer ejemplos de entrada y salida para el entrenamiento, de manera que el modelo pueda reconocer patrones temporales y posibles relaciones no lineales entre las variables meteorológicas y la categoría del mes posterior.

El proyecto se enfocará en clasificar el nivel de amenaza meteorológica asociado a la precipitación del mes siguiente en zonas seleccionadas del Ecuador. El resultado representará el comportamiento esperado de la precipitación respecto a los antecedentes históricos de cada zona y funcionará como una herramienta académica complementaria para el análisis meteorológico anticipado. La clasificación se referirá específicamente a la amenaza meteorológica, considerando que la evaluación del riesgo de desastre requiere además información sobre exposición, vulnerabilidad y capacidad de respuesta [4], [5].

Objetivo

Clasificar el nivel de amenaza por lluvias intensas del mes siguiente en zonas seleccionadas del Ecuador mediante un modelo de aprendizaje automático entrenado con datos climáticos históricos disponibles en fuentes abiertas como Copernicus Climate Data Store disponibles hasta el mes de consulta.

Usuarios Potenciales

Para maximizar el impacto del proyecto, es importante identificar los grupos de usuarios que se benefician de una solución orientada al análisis anticipado de las precipitaciones en el contexto ecuatoriano.

- **Instituciones de gestión de riesgos y planificación territorial:** Facilita la identificación de zonas con niveles elevados de amenaza meteorológica, apoyando el análisis preventivo y la planificación de acciones frente a eventos asociados con lluvias intensas [1].
- **Analistas meteorológicos e instituciones técnicas:** Permite analizar antecedentes climáticos y estimaciones del nivel de amenaza del mes siguiente, considerando la variabilidad espacial y temporal de las precipitaciones según la ubicación, la altitud y la época del año [2], [3].
- **Universidades y centros de investigación:** Actúa como una herramienta académica para estudiar el comportamiento histórico de las precipitaciones y evaluar la

aplicación de técnicas de aprendizaje automático en problemas meteorológicos del Ecuador [2], [3].

La solución funciona como una herramienta complementaria de análisis y no sustituye los pronósticos ni las alertas meteorológicas oficiales. Además, clasifica únicamente la amenaza meteorológica asociada con la precipitación y no el riesgo integral de desastre, el cual también depende de factores como la exposición y la vulnerabilidad [4], [5].

Modelos corregidos de análisis y definición del problema

Datos y parámetros fundamentales del problema

Las entidades y parámetros fundamentales del problema son:

- **Zona geográfica:** ubicación del Ecuador sobre la cual se realiza el análisis, caracterizada por ciudad, provincia, región, latitud y longitud.
- **Periodo meteorológico:** intervalo temporal al que corresponde una observación y que permite mantener su orden cronológico y estacional.
- **Observación meteorológica:** conjunto de indicadores asociados con precipitación, temperatura, humedad relativa, viento y presión atmosférica registrados para una zona y periodo.
- **Ventana histórica:** secuencia ordenada de observaciones conocidas hasta el periodo de consulta, utilizada para caracterizar la evolución meteorológica reciente.
- **Perfil climatológico:** comportamiento histórico de la precipitación para una zona y época del año, representado mediante comportamiento histórico de la precipitación para una zona y época del año
- **Clasificación de amenaza:** categoría baja, media o alta asignada al periodo objetivo.
- **Periodo objetivo:** periodo posterior que se desea clasificar utilizando exclusivamente antecedentes disponibles.


Modelo del flujo de trabajo actual

El proceso actual, representado en la figura 1, requiere recopilar, organizar e interpretar información meteorológica histórica para estimar anticipadamente el comportamiento de las precipitaciones. Este proceso sigue los siguientes pasos:

1. **Adquisición de datos meteorológicos:** Se recopilan registros históricos de precipitación y otras variables meteorológicas asociadas con diferentes zonas geográficas y períodos. La información debe conservar su relación espacial y temporal, debido a que el comportamiento de las precipitaciones varía según la ubicación y la época del año [2], [3].
2. **Preparación y organización de la información:** Los registros son ordenados por zona y periodo, verificando la disponibilidad de antecedentes suficientes y construyendo una secuencia cronológica que permita comparar las condiciones recientes con observaciones anteriores.

3. **Análisis e interpretación manual:** El analista compara las observaciones recientes con el comportamiento histórico de la misma zona y con periodos similares de años anteriores. En esta etapa se revisan tendencias, variaciones y posibles anomalías para estimar el comportamiento de las precipitaciones del mes siguiente. La variabilidad espacial y temporal de la lluvia dificulta aplicar un único criterio para todas las zonas y periodos [2], [3]. Esta interpretación constituye el principal cuello de botella, debido a la cantidad de registros y a las múltiples relaciones que deben evaluarse manualmente.
4. **Clasificación y comunicación del resultado:** A partir del análisis realizado, se asigna una categoría preliminar de amenaza meteorológica baja, media o alta para el periodo siguiente. El resultado se registra como información complementaria para el análisis y la planificación, sin constituir una alerta meteorológica oficial ni una evaluación completa del riesgo de desastre [4], [5].

Este análisis del problema orienta el diseño de una solución basada en aprendizaje automático que automatice la identificación de patrones meteorológicos y reduzca la dependencia de la interpretación manual para clasificar el nivel de amenaza del mes siguiente.




Modelo de actores y necesidades

Los principales actores involucrados en este dominio y sus objetivos son:

- **Analista técnico de información climática:** Su necesidad es analizar de manera eficiente los antecedentes meteorológicos de una zona, considerando la variabilidad espacial y temporal de las precipitaciones. Su objetivo es obtener una clasificación anticipada del nivel de amenaza meteorológica del mes siguiente, junto con información que permita interpretar el resultado [2], [3].
- **Responsable de planificación o gestión de riesgos:** Su necesidad es acceder a información comprensible sobre el nivel estimado de amenaza meteorológica en una zona determinada. Su objetivo es utilizar la clasificación como apoyo complementario para priorizar análisis y preparar acciones preventivas frente a eventos asociados con lluvias intensas [1].

Modelado de Requerimientos Funcionales y Casos de uso

Diagrama UML de casos de uso



Caso de uso 1

Nombre	Consultar antecedentes meteorológicos
ID	CU-01
Actores	Analista técnico de información climática
Descripción	Este caso de uso permite consultar las observaciones meteorológicas disponibles para una zona geográfica y un periodo de referencia. El sistema presenta los antecedentes organizados cronológicamente e indica si existe información suficiente para el análisis. La consulta conserva la relación entre ubicación, periodo y comportamiento estacional, debido a la variabilidad espacial y temporal de las precipitaciones [2], [3].

Historias de usuario

- **HU-01: Consulta histórica por zona:** Como analista técnico de información climática, quiero consultar los antecedentes meteorológicos de una zona y un periodo determinados, para revisar el comportamiento reciente e histórico de las precipitaciones.
- **HU-02: Verificación de disponibilidad de información:** Como analista técnico de información climática, quiero que el sistema me informe si existen antecedentes suficientes para la zona y el periodo seleccionados, para evitar realizar un análisis sin respaldo histórico adecuado.

Caso de uso 2

Nombre	Determinar el nivel de amenaza del mes siguiente
ID	CU-02
Actores	Analista técnico de información climática; responsable de planificación o gestión de riesgos
Descripción	Este caso de uso permite determinar el nivel de amenaza meteorológica asociado con la precipitación del mes siguiente para una zona geográfica y un periodo de referencia. El sistema utiliza exclusivamente los antecedentes disponibles hasta el mes de consulta y genera una categoría de amenaza baja, media o alta. Cuando la información histórica es insuficiente, el sistema no genera una clasificación.

Historias de usuario

- **HU-03: Clasificación anticipada por zona:** Como analista técnico de información climática, quiero obtener la clasificación del nivel de amenaza meteorológica del mes siguiente para una zona seleccionada, para apoyar el análisis anticipado de las precipitaciones.
- **HU-04: Validación previa a la clasificación:** Como analista técnico de información climática, quiero que el sistema verifique la disponibilidad de antecedentes antes de ejecutar la clasificación, para evitar obtener resultados basados en información insuficiente.

Caso de uso 3

Nombre	Visualizar resultados de la clasificación
ID	CU-03
Actores	Analista técnico de información climática; responsable de planificación o gestión de riesgos

Descripción	Este caso de uso permite visualizar la zona consultada, el mes de referencia, el mes objetivo, la categoría de amenaza estimada, las probabilidades asociadas con las categorías baja, media y alta y los antecedentes meteorológicos relacionados con la consulta. La información se presenta de forma comprensible para apoyar el análisis meteorológico y la planificación preventiva.
--------------------	---

Historias de usuario

- **HU-05: Visualización del resultado:** Como responsable de planificación o gestión de riesgos, quiero visualizar claramente la categoría de amenaza estimada, la zona analizada y el periodo objetivo, para utilizar el resultado como información complementaria durante la planificación preventiva.
- **HU-06: Consulta de probabilidades y antecedentes:** Como analista técnico de información climática, quiero consultar las probabilidades de cada categoría y los antecedentes meteorológicos relacionados, para analizar el contexto y el nivel de confianza de la clasificación.

Modelos completos de diseño de la solución

Descripción general de la solución

La solución propuesta consistirá en un sistema académico basado en aprendizaje automático supervisado para clasificar el nivel de amenaza meteorológica por lluvias intensas del mes siguiente en zonas seleccionadas del Ecuador.

Para una zona geográfica zzz y un mes de referencia t , la solución recibirá información meteorológica disponible hasta dicho periodo y generará una clasificación para el mes $t + 1$:

$$X_{z,t} \rightarrow \hat{Y}_{z,t+1}$$

donde:

- $X_{z,t}$ representa los antecedentes meteorológicos disponibles hasta el mes de consulta.
- $\hat{Y}_{z,t+1}$ representa la categoría estimada para el mes siguiente.
- La salida pertenece a las categorías **Baja**, **Media** o **Alta**.

La información de entrada estará organizada en cinco grupos:

1. Indicadores de precipitación acumulada.
2. Indicadores de intensidad y persistencia de las lluvias.
3. Variables de temperatura y humedad atmosférica.
4. Variables de viento y presión superficial.
5. Información temporal y geográfica.

La solución se dividirá en dos procesos principales:

Proceso de entrenamiento y selección

Este proceso tendrá como finalidad comparar los modelos candidatos y obtener un modelo entrenado y validado. Comprenderá:


- Preparación de las características.
- División temporal y espacial del conjunto de datos.
- Entrenamiento de los cinco algoritmos.
- Evaluación sobre validación temporal.
- Comparación de métricas.
- Selección del modelo definitivo.
- Evaluación temporal y espacial final.
- Almacenamiento del modelo seleccionado.

Proceso de inferencia

Este proceso se ejecutará cuando un usuario solicite una clasificación para una zona y periodo determinados. Comprenderá:

- Selección de zona y mes de referencia.
- Recuperación de antecedentes meteorológicos.
- Verificación de disponibilidad de información.
- Construcción del vector de entrada.
- Ejecución del modelo seleccionado.
- Obtención de la categoría y sus probabilidades.
- Presentación de antecedentes y resultado.

Diagrama general de arquitectura



La arquitectura estará compuesta por seis módulos lógicos.

A. Repositorio meteorológico

Almacenará las observaciones históricas y los conjuntos de datos derivados necesarios para el entrenamiento y la consulta.

Contendrá:

- Observaciones meteorológicas históricas.
- Indicadores mensuales.
- Antecedentes por zona.
- Categorías históricas.
- Reportes de calidad.

B. Módulo de preparación de características

Será responsable de convertir las observaciones mensuales en vectores de entrada adecuados para los modelos.

Sus funciones de diseño serán:

- Seleccionar los indicadores meteorológicos.
- Organizar los meses en orden cronológico.
- Construir ventanas históricas.
- Incorporar información estacional y geográfica.
- Excluir variables futuras o relacionadas directamente con la respuesta.
- Aplicar transformaciones requeridas por cada algoritmo.

C. Gestor de particiones

Separará los registros respetando el orden temporal y la validación geográfica.

Las particiones serán:

- Entrenamiento: periodos hasta 2017.
- Validación temporal: 2018–2021.
- Prueba temporal: 2022–2025.
- Validación espacial: zonas reservadas que no participarán en el entrenamiento.
- Historia de las zonas de validación espacial: excluida del ajuste de los modelos.

Esta separación evita utilizar información futura durante el entrenamiento y permite evaluar si la solución funciona tanto en periodos posteriores como en zonas no vistas.

D. Motor de entrenamiento y comparación

Administrará los cinco modelos candidatos mediante una interfaz común.

Cada modelo deberá permitir:

- entrenar()
- predecir()
- predecirProbabilidades()
- obtenerConfiguracion()

El motor garantizará que todos los algoritmos sean evaluados con:

- Las mismas observaciones.
- Las mismas particiones.
- La misma variable objetivo.
- El mismo conjunto de características por experimento.
- Las mismas métricas.

E. Selector de modelo

Comparará los resultados obtenidos en validación temporal y determinará el modelo que será llevado a evaluación final.

La selección considerará:

- Macro F1.
- Exactitud balanceada.
- Recall de la clase Alta.
- F1 por clase.
- Diferencia entre entrenamiento y validación.
- Tiempo de inferencia.
- Interpretabilidad.

Una vez seleccionado, el modelo será evaluado en la prueba temporal y en la zonas de validación espacial.

F. Servicio de inferencia y presentación

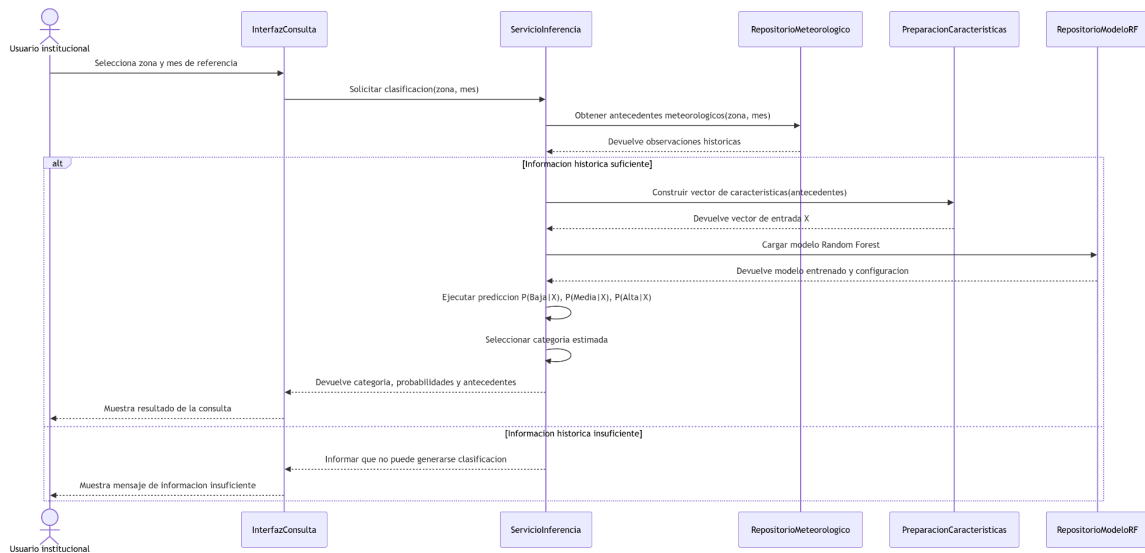
Cargará el modelo seleccionado y atenderá las solicitudes del usuario.

La respuesta incluirá:

- Zona consultada.
- Mes de referencia.
- Mes objetivo.
- Categoría estimada.
- Probabilidad de amenaza Baja.
- Probabilidad de amenaza Media.
- Probabilidad de amenaza Alta.


- Antecedentes meteorológicos utilizados.
- Estado de disponibilidad de información.

Diagrama de secuencia del proceso de consulta



La figura presenta el diagrama de secuencia correspondiente al proceso de consulta de la solución propuesta. El flujo inicia cuando el usuario institucional selecciona una zona geográfica y un mes de referencia en la interfaz de consulta. La solicitud es enviada al servicio de inferencia, el cual recupera los antecedentes meteorológicos desde el repositorio histórico. Si la información disponible es suficiente, el sistema solicita al módulo de preparación de características la construcción del vector de entrada y posteriormente carga el modelo Random Forest entrenado desde el repositorio de modelos. A continuación, ejecuta la predicción, calcula las probabilidades de las categorías Baja, Media y Alta, y determina la clase estimada. Finalmente, el resultado es devuelto a la interfaz y presentado al usuario. Si los antecedentes no son suficientes, el sistema informa que no es posible generar la clasificación.


Diagrama de actividades



La figura presenta el diagrama de actividades correspondiente al proceso de consulta de la solución propuesta. El flujo inicia cuando el usuario institucional selecciona una zona geográfica y un periodo mensual de referencia, y solicita la clasificación de amenaza. A continuación, el sistema recupera los antecedentes meteorológicos disponibles y verifica que exista información suficiente para realizar el análisis.

Cuando los antecedentes son insuficientes, el sistema informa esta condición al usuario y finaliza el proceso sin generar una clasificación. En caso contrario, organiza la ventana histórica y construye las características de entrada requeridas por el modelo. El modelo Random Forest analiza los patrones temporales, geográficos y meteorológicos, y estima las probabilidades correspondientes a las categorías de amenaza Baja, Media y Alta. Posteriormente, el sistema selecciona la categoría con mayor probabilidad y presenta al usuario la clasificación estimada junto con los antecedentes meteorológicos relacionados.

Arquitectura del modelo principal: Random Forest



5.3.1 Entrada del modelo

Random Forest recibirá un vector tabular compuesto por características seleccionadas de los siguientes grupos:

Grupo	Variables representativas
Precipitación acumulada	precipitación total, Rx1day y Rx5day
Intensidad	máximos de 1, 3 y 6 horas, SDII
Frecuencia y persistencia	días húmedos, R10mm, R20mm, CWD y CDD
Condiciones atmosféricas	temperatura, punto de rocío, humedad relativa, viento y presión
Contexto	mes del año, latitud y longitud

5.3.2 Construcción del bosque

El modelo estará compuesto por múltiples árboles de decisión.

Cada árbol será entrenado mediante:

- Una muestra de registros del conjunto de entrenamiento.
- Un subconjunto aleatorio de variables en cada división.
- Reglas de decisión propias para distinguir las tres categorías.

La aleatoriedad en las muestras y características permitirá que los árboles aprendan patrones diferentes.

5.3.3 Agregación de predicciones

Cada árbol generará una predicción individual:

- ★ Baja
- ★ Media
- ★ Alta

Random Forest combinará las decisiones de todos los árboles. La probabilidad de una categoría se podrá expresar como:

$$P(c | X) = \frac{\text{número de árboles que seleccionan } c}{\text{número total de árboles}}$$

La clasificación final será:


$$\hat{Y} = \underset{c \in \{Baja, Media, Alta\}}{\operatorname{argmax}} P(c | X)$$

5.3.4 Justificación del modelo principal

Random Forest se mantiene como la propuesta principal porque:

- Es apropiado para datos tabulares.
- Puede representar relaciones no lineales.
- Captura interacciones entre distintos indicadores meteorológicos.
- Maneja variables en diferentes escalas sin exigir estandarización.
- Reduce la inestabilidad de un árbol individual.
- Permite calcular la importancia de las características.
- Puede controlar el sobreajuste mediante la profundidad de los árboles y el tamaño mínimo de sus nodos.

Algoritmos que serán comparados



Se evaluarán cinco modelos de clasificación multiclase.

Modelo	Papel
Random Forest	Modelo principal propuesto
Regresión Logística Multinomial	Modelo lineal de referencia
XGBoost	Alternativa de ensamble por boosting
SVM con kernel RBF	Alternativa no lineal basada en márgenes
MLP	Alternativa basada en red neuronal

Regresión Logística Multinomial: Se utilizará como modelo de referencia debido a su simplicidad e interpretabilidad. Permitirá determinar si las categorías de amenaza pueden separarse mediante relaciones aproximadamente lineales entre las variables meteorológicas. Requerirá estandarización de las características.

XGBoost: Representará una estrategia de ensamble diferente a Random Forest. Mientras Random Forest construye árboles relativamente independientes y combina sus resultados, XGBoost genera árboles de forma secuencial, donde cada nuevo árbol busca corregir los errores del conjunto anterior. Permitirá evaluar si el aprendizaje progresivo mejora la clasificación de los patrones meteorológicos.

SVM con kernel RBF: Permitirá construir fronteras no lineales entre las tres categorías en un espacio de múltiples características. Será útil para evaluar si las clases pueden separarse mediante relaciones complejas que no son captadas por un modelo lineal. Requerirá estandarización de las entradas.

MLP: La red neuronal multicapa permitirá comparar los modelos tradicionales con una arquitectura neuronal moderada. Su diseño preliminar estará compuesto por:

Vector de características → Capa oculta → Capa oculta → Capa oculta → Capa de salida
Softmax

La capa de salida tendrá tres neuronas, una para cada categoría:

- ★ Baja
- ★ Media
- ★ Alta

La profundidad se mantendrá moderada para reducir el riesgo de sobreajuste sobre un conjunto tabular de tamaño limitado.

Criterio de selección

El modelo definitivo será el que obtenga el mejor Macro F1 en validación temporal, siempre que mantenga un recall adecuado para la categoría Alta y no presente evidencia marcada de sobreajuste. Si dos modelos obtienen resultados similares, se priorizará aquel con mejor generalización espacial, mayor interpretabilidad y menor costo de inferencia.

Implementación preliminar

Plataforma y lenguaje de programación

La implementación computacional se desarrollará en Python 3.10+. La elección de este lenguaje no obedece únicamente a su adopción generalizada, sino a su capacidad para interactuar con rutinas subyacentes compiladas en C y C++ (esenciales para el procesamiento vectorizado de matrices climáticas masivas) y a su soporte nativo para tensores multidimensionales a través de su ecosistema científico.

Fuente y preparación de los datos

La información base se obtendrá del catálogo global Copernicus Climate Data Store (CDS), extrayendo específicamente el producto de reanálisis ERA5-Land. Este dataset ofrece una resolución espacial óptima y continuidad temporal, cubriendo los "puntos ciegos" donde las estaciones meteorológicas físicas no tienen alcance.

Los datos se descargan en formato multidimensional NetCDF (.nc), el cual almacena la información en matrices tridimensionales (latitud, longitud y tiempo). El proceso de preparación (ETL) consistirá en:

- Recorte espacial (Clipping): Filtrar únicamente el Bounding Box correspondiente al territorio continental del Ecuador.
- Agregación temporal: Convertir los datos horarios o diarios en acumulados y promedios mensuales, alineándose con el objetivo del problema.
- Aplanamiento (Flattening): Transformar la matriz multidimensional en un formato tabular tradicional (DataFrame), donde cada fila representará una única observación caracterizada por su zona geográfica y su mes específico.

Variables de entrada y variable objetivo

Para que los algoritmos de Machine Learning tabular puedan comprender la secuencialidad del clima, se transformará el conjunto de datos estático en un formato autorregresivo:

Variables de entrada ($X_{z,t}$):

Además de las mediciones del mes de consulta t (precipitación acumulada, temperaturas extremas y medias), se construirán variables de rezago temporal (lags) introduciendo los valores correspondientes a los meses anteriores ($t-1$, $t-2$).

Variable objetivo ($Y_{z,t+1}$)

Será categórica discreta multiclase (Baja, Media, Alta). Para evitar la fuga de datos (data leakage) y garantizar la pertinencia geográfica, las etiquetas de entrenamiento no usarán umbrales estáticos globales, sino que se calcularán dinámicamente aplicando el Percentil 33 y

Percentil 66 sobre la distribución histórica multianual específica de cada píxel (coordenada) para cada mes.

Librerías y herramientas

- *Procesamiento Geoespacial y Extracción*
cdsapi para automatizar las peticiones de descarga al servidor de Copernicus. xarray y netCDF4, las cuales están optimizadas para abrir, leer y realizar operaciones matemáticas sobre arreglos climáticos multidimensionales sin saturar la memoria RAM.
- *Manipulación Tabular*
pandas y numpy para la limpieza de nulos, estructuración del DataFrame final, cálculo de percentiles y generación de variables desfasadas (lags).
- *Modelado Predictivo*
scikit-learn como motor principal de Inteligencia Artificial. Proveerá las implementaciones de los algoritmos (Random Forest y Regresión Logística Multinomial), así como las funciones para la división de datos (Time-Series Split) y el cálculo de métricas (Matriz de confusión, Recall, F1-Score).
- *Visualización*
matplotlib y seaborn para el análisis exploratorio estático, y plotly para renderizar gráficos interactivos de series de tiempo.
- *Persistencia y Despliegue*
joblib para serializar (guardar) el modelo entrenado y sus escaladores, permitiendo cargarlos instantáneamente en el entorno de producción.

Resultados esperados

Se espera obtener un conjunto de datos meteorológicos mensuales, estructurado y validado por zona geográfica, a partir de información histórica pública. Con estos datos se entrenarán y compararán cinco modelos de clasificación: Random Forest, Regresión Logística Multinomial, XGBoost, SVM con kernel RBF y MLP, manteniendo Random Forest como modelo principal propuesto.

El desempeño se evaluará mediante particiones cronológicas y espaciales, utilizando como métrica principal el F1-score macro, además de exactitud balanceada, precisión, recall y F1 por categoría, matrices de confusión y recall de la categoría Alta. El modelo final se seleccionará con la validación temporal y posteriormente se evaluará en la prueba temporal y en zonas no utilizadas durante el entrenamiento.

Finalmente, se desarrollará un prototipo web que permita seleccionar una zona y un periodo, y visualizar la amenaza estimada para el mes siguiente, las probabilidades de cada categoría y los antecedentes meteorológicos empleados.

Posibilidades futuras

El proyecto podría servir como base para un emprendimiento, aunque requeriría una evolución importante antes de convertirse en un producto comercial.

La solución podría ampliarse como una plataforma de apoyo para municipios, empresas agrícolas, aseguradoras o instituciones de gestión de riesgos, incorporando más zonas, actualización automática de datos, mapas interactivos, reportes y notificaciones preventivas.

Sin embargo, para su uso real sería necesario validar el modelo con especialistas, integrar fuentes meteorológicas oficiales y datos más recientes, mejorar la resolución geográfica y demostrar su desempeño operativo. Por ello, actualmente su valor principal es académico, pero puede constituir una base técnica para una futura herramienta comercial de análisis meteorológico, sin presentarse todavía como un sistema oficial de pronóstico o alerta.

Referencias

- [1] Secretaría Nacional de Gestión de Riesgos, Dirección de Monitoreo de Eventos Adversos, “SitRep No. 130: Por lluvias, del 1 de enero de 2026 a la fecha,” Ecuador, 10 jul. 2026.
- [2] L. Silva, R. Céleri and M. Córdova, “Diurnal to seasonal meteorological cycles along an equatorial Andean elevational gradient,” *Atmósfera*, vol. 39, pp. 33–48, 2025, doi: 10.20937/ATM.53369.
- [3] R. Celleri, P. Willems, W. Buytaert and J. Feyen, “Space-time rainfall variability in the Paute basin, Ecuadorian Andes,” *Hydrological Processes*, vol. 21, no. 24, pp. 3316–3327, 2007, doi: 10.1002/hyp.6575.
- [4] United Nations Office for Disaster Risk Reduction, “Hazard,” Sendai Framework Terminology on Disaster Risk Reduction, 2017, consultado: 24 jul. 2026.
- [5] United Nations Office for Disaster Risk Reduction, “Disaster risk,” Sendai Framework Terminology on Disaster Risk Reduction, 2017, consultado: 24 jul. 2026.

Anexo de sesiones realizadas con herramientas de IA

URLs de las conversaciones:

<https://chatgpt.com/share/6a6985ea-ab1c-83e9-9a8d-5cdf70a6a562>

<https://chatgpt.com/share/6a6987af-f040-83e9-ad95-d1ded15e3843>

<https://share.gemini.google/QNokuFK4Vs90>

IA utilizada: ChatGPT y Gemini

Integración de las respuestas en los modelos de diseño

La inteligencia artificial se utilizó como apoyo para revisar la estructura de la tarea, organizar la descripción de la solución y proponer versiones preliminares de los diagramas. Las respuestas obtenidas permitieron identificar los componentes principales de la arquitectura, diferenciar el proceso de entrenamiento del proceso de inferencia y representar de manera más clara la participación del usuario, el sistema y el modelo Random Forest.

Las propuestas generadas fueron revisadas y adaptadas por el grupo para mantener coherencia con el problema planteado y con el alcance mensual definido. A partir de este proceso se elaboraron el diagrama general de arquitectura, el diagrama de secuencia, el diagrama de actividades, la arquitectura de Random Forest y el diagrama comparativo de algoritmos. También se ajustaron aspectos como las particiones cronológicas, las métricas de evaluación, la validación espacial y la información que mostrará el prototipo.

Reflexión grupal sobre la utilidad de las herramientas de IA

Como grupo, consideramos que las herramientas de IA fueron útiles para organizar ideas, aclarar conceptos de aprendizaje automático y generar estructuras iniciales para los modelos de diseño. También facilitaron la revisión de los diagramas y permitieron detectar inconsistencias entre la descripción escrita y la arquitectura propuesta.

Sin embargo, las respuestas no fueron utilizadas de manera “automática”. Fue necesario revisarlas, resumirlas y corregirlas, ya que en algunos casos incluían elementos que no correspondían al alcance de la solución, presentaban un nivel de detalle excesivo o proponían componentes adicionales que no eran necesarios. Por esta razón, la IA fue utilizada como una herramienta de apoyo y no como sustituto del análisis y las decisiones del grupo.

¿Agregaron sus propios criterios en la selección de los componentes y su definición, más allá de las respuestas generadas por las herramientas basadas en IA?

El grupo incorporó criterios propios para adaptar las propuestas al alcance real del proyecto. Entre las decisiones tomadas se encuentran mantener el análisis en periodos mensuales, usar

Random Forest como modelo principal, separar la arquitectura final del proceso comparativo de algoritmos, respetar particiones cronológicas y espaciales, y priorizar métricas como el F1-score macro y el recall de la categoría Alta. Además, se revisaron y simplificaron los componentes y diagramas para evitar elementos innecesarios y mantener coherencia con el problema, el conjunto de datos y las instrucciones de la tarea.

¿Encontraron algún beneficio o limitación de las herramientas basadas en IA?

El principal beneficio fue la rapidez para organizar ideas, aclarar conceptos, mejorar la redacción y generar propuestas iniciales de diagramas y estructuras de diseño. Sin embargo, también se identificaron limitaciones, como respuestas demasiado extensas, sugerencias fuera del alcance, componentes adicionales no requeridos y errores de sintaxis en algunos diagramas. Por ello, las respuestas tuvieron que ser revisadas, corregidas y adaptadas por el grupo antes de incorporarlas al documento.